# Przetwarzanie języka naturalnego

Sprawozdanie z laboratoriów 1–5

Język serbski: analiza statystyczna (entropia, Huffman, prawo Zipfa, pokrycie 90% tekstu, rdzeń języka), analiza syntaktyczna (generator zdań SVO) i analiza semantyczna (klasyfikator rzeczowników – sieć Kohonena)



| | |
|---|---|
| **Autor** | Przemysław Kondrat |
| **Język korpusu** | serbski (cyrylica, 30 liter) |
| **Źródło danych** | serbska Wikipedia (sr.wikipedia.org), API MediaWiki |
| **Język programowania** | Python 3 (numpy, scipy, matplotlib, networkx, stanza, reportlab) |
| **Data** | 08.11.2026 |

# Spis treści

**Wprowadzenie** **4**

Struktura programu . . . 4

Słowniczek pojęć . . . 5

**1. Laboratorium 1 – wybór języka i przygotowanie korpusu** **6**

1.1. Jak to zrobiliśmy . . . 6

1.2. Wynik czyszczenia . . . 6

**2. Laboratorium 2 – statystyka liter, entropia i kodowanie Huffmana** **8**

2.1. Jak to zrobiliśmy . . . 8

2.2. Udział liter – prawdopodobieństwa . . . 8

2.3. Entropia i kod Huffmana – jak działają (na małym przykładzie) . . . 9

2.4. Wyniki dla całego korpusu . . . 10

**3. Laboratorium 3 – pokrycie tekstu, prawo Zipfa, graf sąsiedztwa** **12**

3.1. Wyrazy pokrywające 90% tekstu . . . 12

3.2. Prawo Zipfa . . . 13

3.3. Graf wyrazów sąsiadujących i jego rdzeń . . . 14

**4. Laboratorium 4 – analiza semantyczna: klasyfikator rzeczowników oparty na sieci Kohonena** **18**

4.1. Korpus do analizy semantycznej . . . 18

4.2. Analiza składniowa i frazy VO . . . 19

4.3. Wybór 100 czasowników przechodnich i 1000 rzeczowników . . . 19

4.4. Zbiór treningowy – wektory o 100 składowych . . . 21

4.5. Sieć Kohonena – budowa i uczenie . . . 21

4.6. Wynik – klastry rzeczowników . . . 22

4.7. Analiza klastrów . . . 26

**5. Laboratorium 5 – analiza syntaktyczna: generator zdań SVO** **29**

5.1. Leksykon . . . 29

5.2. Fraza rzeczownikowa i jej odmiana . . . 32

5.3. Orzeczenie: czasy, tryby i strony . . . 32

5.4. Szyk zdania i enklityki . . . 33

5.5. Ograniczenia znaczeniowe . . . 33

5.6. Wyniki . . . 34

**6. Sprawdzenie poprawności wyników** **36**

**7. Podsumowanie** **37**

Realizacja wymagań . . . 37

Najważniejsze wnioski . . . 37

Uruchomienie programu . . . . . 37
Bibliografia . . . . . 38

# Wprowadzenie

Celem laboratoriów było przeanalizowanie wybranego języka naturalnego na trzech poziomach:

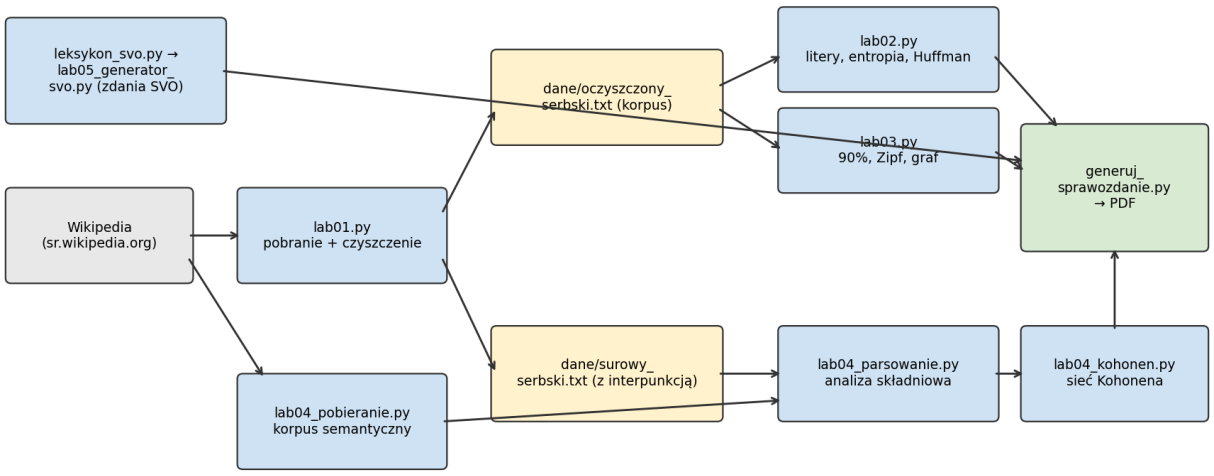
- **analiza statystyczna** (rozdziały 1–3): korpus ponad 100 000 wyrazów, statystyka liter, entropia i kod Huffmana, prawo Zipfa, lista wyrazów pokrywających 90% tekstu, rdzeń języka (100 wyrazów o największej liczbie sąsiadów),
- **analiza semantyczna** (rozdział 4): klasyfikator semantyczny 1000 rzeczowników – sieć Kohonena z 50 neuronami ucząca się na frazach czasownik–dopełnienie,
- **analiza syntaktyczna** (rozdział 5): generator zdań prostych SVO we wszystkich czasach, trybach i stronach.

**Wybrany język: serbski.** Serbski zapisuje się m.in. cyrylicą, która ma dokładnie 30 liter, a każda litera odpowiada jednej głosce (zasada „piši kao što govoriš” – pisz tak, jak mówisz). Dzięki temu łatwo sprawdzić, że w korpusie zostały wyłącznie litery alfabetu. Bogata odmiana wyrazów przez przypadki jest z kolei ciekawa przy badaniu prawa Zipfa i wymaga analizy składniowej w laboratorium 4.

**Dane:** korpus podstawowy – 20 artykułów z serbskiej Wikipedii (ok. 1 mln znaków), głównie o historii i geografii Serbii i regionu; do analizy semantycznej dodatkowo ok. 8 mln znaków z artykułów o różnej tematyce (rozdział 4.1).

## Struktura programu

Każde laboratorium to osobny skrypt w Pythonie. Wspólne ustawienia (alfabet, ścieżki do plików) są w `wspolne.py`, a `uruchom_wszystko.py` uruchamia wszystkie etapy po kolei. Skrypt `sprawdz_wyniki.py` niezależnie przelicza wyniki i potwierdza ich poprawność (rozdział 6). Kod i wyniki są w repozytorium GitHub; opis uruchomienia jest w pliku README.md.




*Rys. 1. Schemat działania programu – przepływ danych między skryptami.*

## Słowniczek pojęć

| Pojęcie | Wyjaśnienie |
|---|---|
| korpus | duży zbiór tekstu przygotowany do analizy; u nas: same wyrazy z liter serbskiego alfabetu |
| token / typ | token to każde wystąpienie wyrazu w tekście, typ to różny wyraz (w zdaniu „и ја и ти” są 4 tokeny i 3 typy) |
| lemat | forma podstawowa wyrazu, np. цркву, цркве, црквом → црква (cerkiew) |
| prawdopodobieństwo p | udział litery w tekście: p = liczba wystąpień / liczba wszystkich liter |
| entropia H | średnia liczba bitów na znak, poniżej której nie da się zakodować tekstu (miara „nieprzewidywalności” tekstu) |
| kod Huffmana | kod, w którym częste znaki dostają krótkie ciągi bitów, a rzadkie długie; najkrótszy możliwy kod przypisujący każdemu znakowi stały ciąg bitów |
| kod prefiksowy | żaden kod nie jest początkiem innego, więc tekst da się odczytać bez separatorów |
| prawo Zipfa | częstość wyrazu jest odwrotnie proporcjonalna do jego miejsca w rankingu: 2. wyraz występuje ok. 2 razy rzadziej niż 1., 3. ok. 3 razy rzadziej itd. |
| hapax legomenon | wyraz, który występuje w tekście tylko raz |
| graf, węzeł, krawędź | węzły to wyrazy, krawędź łączy dwa wyrazy stojące w tekście obok siebie |
| stopień węzła | liczba krawędzi wychodzących z węzła, czyli liczba różnych sąsiadów wyrazu |
| rdzeń grafu | 100 węzłów o największej liczbie sąsiadów |
| czasownik przechodni | czasownik, który łączy się z dopełnieniem w bierniku: „podjąć *decyzję*”, „zdobyć *miasto*” |
| fraza VO | połączenie czasownika z jego dopełnieniem bliższym, np. попити воду (wypić wodę) |
| pole semantyczne | grupa wyrazów o wspólnym zakresie znaczeniowym, np. jedzenie, pojazdy, budynki |
| neuron martwy | neuron sieci Kohonena, który po uczeniu nie jest zwycięzcą dla żadnego wektora |
| zdanie SVO | zdanie o szyku podmiot (S) – orzeczenie (V) – dopełnienie (O) |
| enklityka | krótki wyraz bez akcentu (сам, је, га, се, ће), który w serbskim stoi na drugim miejscu w zdaniu |
| wektor cech | opis obiektu listą liczb; u nas rzeczownik = 100 liczb (po jednej na czasownik) |
| sieć Kohonena (SOM) | sieć neuronowa ucząca się bez nauczyciela, która układa podobne obiekty w tych samych lub sąsiednich neuronach |
| neuron zwycięski (BMU) | neuron sieci najbardziej podobny do danego wektora wejściowego |

*Tabela 1. Najważniejsze pojęcia używane w sprawozdaniu.*

# 1. Laboratorium 1 – wybór języka i przygotowanie korpusu

**Zadanie:** wybrać język, pobrać duży tekst w tym języku i zostawić z niego sam korpus wyrazów: bez znaków specjalnych, interpunkcji, liczb i znaków spoza alfabetu.

> **W prostych słowach**
> Komputer ma liczyć litery i wyrazy, więc tekst musi być „czysty”. Gdyby zostały w nim kropki, cyfry albo angielskie słowa, zafałszowałyby statystyki: kropka liczyłaby się jako litera, a „1389” jako wyraz. Dlatego zostawiamy tylko 30 małych liter serbskiej cyrylicy oddzielonych pojedynczymi spacjami.

## 1.1. Jak to zrobiliśmy

1. **Pobranie tekstu.** Skrypt `lab01.py` pobiera artykuły z serbskiej Wikipedii przez oficjalne API (sam tekst, bez kodu strony), aż zbierze ok. 1 000 000 znaków. Pomija artykuły krótsze niż 5000 znaków (szablonowe zalążki) i duplikaty, a między zapytaniami czeka 1,5 s, żeby nie obciążać serwera.
2. **Zamiana na małe litery** – „Србија” i „србија” to ten sam wyraz.
3. **Usunięcie znaków spoza alfabetu** – każdy znak, który nie jest jedną z 30 liter (`абвгдђежзијклљмнњопрстћуфхцчџш`), zamieniamy na spację. Jedno wyrażenie regularne `[^абв…ш]` usuwa naraz cyfry, interpunkcję, symbole, łacinkę i grekę.
4. **Zwinięcie spacji** – kilka spacji lub nowych linii z rzędu zamieniamy na jedną spację.
5. **Kontrola** – skrypt liczy, ile znaków każdego rodzaju usunął, i sprawdza, czy w wyniku zostały tylko litery i spacje.

Pobrane artykuły (20): Србија, Историја Србије, Београд, Нови Сад, Ниш, Крагујевац, Војводина, Косово и Метохија, Црна Гора, Босна и Херцеговина, Хрватска, Југославија, Социјалистичка Федеративна Република Југославија, Краљевина Југославија, Краљевина Србија, Српско царство, Немањићи, Стефан Немања, Свети Сава, Стефан Душан.

## 1.2. Wynik czyszczenia

| Grupa usuniętych znaków | Liczba | Przykłady (od najczęstszych) |
|---|---|---|
| białe znaki (spacje, nowe linie) | 159 836 | ↵ ␣ \u2009 \u2003 |
| interpunkcja (. , ( ) – „ ” % …) | 29 766 | , . ) ( - — : „ ” % ; “ |
| cyfry i liczby (np. 1, 2, ²) | 21 112 | 1 0 9 2 3 8 4 5 7 6 ² |
| litery łacińskie | 4 007 | i a m e n k r s o t v c |
| symbole (= + ° € …) | 3 921 | = ° + € − \| > |
| litery greckie | 190 | α σ ρ ο ι ν β ς κ ί τ ε |
| cyrylica spoza alfabetu serbskiego | 14 | ь ъ ѣ й ї ю |
| litery innych alfabetów | 6 | ن ی ش |

*Tabela 2. Znaki usunięte z tekstu surowego. Białe znaki nie znikają: zamieniane są na pojedynczą spację oddzielającą wyrazy.*

| Wielkość | Wartość |
|---|---|
| Liczba znaków tekstu surowego | 1 036 853 |
| Liczba znaków po oczyszczeniu | 967 373 |
| Wielkie litery zamienione na małe | 34 154 |
| Liczba wyrazów (tokenów) | 149 373 |
| Liczba różnych wyrazów (typów) | 25 608 |
| Różne znaki w korpusie | 31 (30 liter + spacja) |

*Tabela 3. Korpus przed i po oczyszczeniu.*

Przykład – zdanie z tekstu surowego i to samo zdanie po oczyszczeniu:

```
Према истом извору, Вишеслав је потицао из лозе неименованог српског кнеза који је за време владавне
цара Ираклија (610–641) довео свој народ у Далмацију и околне области, зачетник је лозе Вишеславића.

према истом извору вишеслав је потицао из лозе неименованог српског кнеза који је за време владавне
цара ираклија довео свој народ у далмацију и околне области зачетник је лозе вишеславића
```

**Wniosek:** w korpusie zostały wyłącznie wyrazy złożone z liter serbskiego alfabetu. Potwierdza to zarówno kontrola w lab01.py, jak i niezależne testy z rozdziału 5. Korpus zapisano w dane/oczyszczony_serbski.txt, a tekst surowy w dane/surowy_serbski.txt (potrzebny w lab 4, bo do analizy składniowej niezbędne są granice zdań).

# 2. Laboratorium 2 – statystyka liter, entropia i kodowanie Huffmana

**Zadanie:** upewnić się, że został sam korpus; w tabeli podać udział procentowy każdej litery (prawdopodobieństwa); policzyć entropię tekstu; wyznaczyć ciągi kodowe Huffmana i porównać je z entropią.

**W prostych słowach**

Komputer zapisuje każdą literę jako ciąg zer i jedynek (bitów). Gdyby każda z 30 liter miała kod tej samej długości, potrzebowalibyśmy 5 bitów na literę ($2^5 = 32 \geq 30$). Litery nie są jednak równie częste: „a” pojawia się ponad 600 razy częściej niż „ų”. **Kod Huffmana** wykorzystuje to i daje częstym literom krótkie kody, a rzadkim długie, więc średnio wychodzi mniej bitów. **Entropia** mówi, ile bitów na literę wystarczy w najlepszym możliwym przypadku. Porównujemy więc, jak blisko tego ideału jest Huffman.

## 2.1. Jak to zrobiliśmy

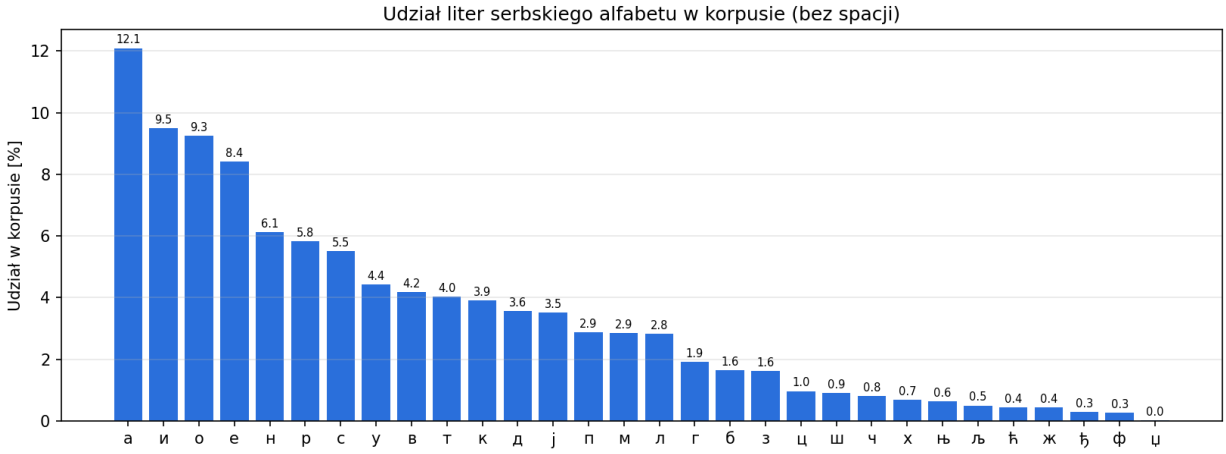
1. Skrypt `lab02_entropia_huffman.py` wczytuje korpus i jeszcze raz sprawdza, że nie ma w nim żadnego znaku spoza alfabetu i spacji. Wynik: brak obcych znaków, występują wszystkie 30 liter.
2. Liczy wystąpienia każdej litery (słownik *Counter*) i dzieli przez liczbę wszystkich liter. Tak powstaje prawdopodobieństwo p każdej litery.
3. Liczy entropię ze wzoru Shannona.
4. Buduje kod Huffmana algorytmem z kolejką priorytetową (opis i przykład w p. 2.3).
5. Koduje cały korpus, dekoduje go z powrotem i sprawdza, czy wyszedł identyczny tekst.
6. Wszystko liczy w dwóch wariantach: same litery (30 symboli) oraz litery + spacja (31 symboli).

## 2.2. Udział liter – prawdopodobieństwa

Korpus bez spacji zawiera 818 001 liter. Tabela podaje dla każdej litery liczbę wystąpień, udział procentowy i prawdopodobieństwo p, a także „idealną” długość kodu $-\log_2 p$ i faktyczny kod Huffmana (omówione w p. 2.3–2.4).

| Lp | Litera | Liczność | Udział [%] | p | $-\log_2 p$ | Kod Huffmana | Dł. kodu |
|---|---|---|---|---|---|---|---|
| 1 | **а** | 98 931 | 12,094 | 0,12094 | 3,048 | 100 | 3 |
| 2 | **и** | 77 660 | 9,494 | 0,09494 | 3,397 | 001 | 3 |
| 3 | **о** | 75 716 | 9,256 | 0,09256 | 3,433 | 000 | 3 |
| 4 | **е** | 68 784 | 8,409 | 0,08409 | 3,572 | 1110 | 4 |
| 5 | **н** | 50 077 | 6,122 | 0,06122 | 4,030 | 0111 | 4 |
| 6 | **р** | 47 619 | 5,821 | 0,05821 | 4,102 | 0110 | 4 |
| 7 | **с** | 45 048 | 5,507 | 0,05507 | 4,183 | 0100 | 4 |
| 8 | **у** | 36 186 | 4,424 | 0,04424 | 4,499 | 11111 | 5 |
| 9 | **в** | 34 121 | 4,171 | 0,04171 | 4,583 | 11011 | 5 |
| 10 | **т** | 32 984 | 4,032 | 0,04032 | 4,632 | 11010 | 5 |
| 11 | **к** | 32 069 | 3,920 | 0,03920 | 4,673 | 11001 | 5 |
| 12 | **д** | 29 088 | 3,556 | 0,03556 | 4,814 | 11000 | 5 |
| 13 | **ј** | 28 824 | 3,524 | 0,03524 | 4,827 | 10110 | 5 |
| 14 | **п** | 23 457 | 2,868 | 0,02868 | 5,124 | 10100 | 5 |
| 15 | **м** | 23 324 | 2,851 | 0,02851 | 5,132 | 01011 | 5 |
| 16 | **л** | 23 043 | 2,817 | 0,02817 | 5,150 | 01010 | 5 |
| 17 | **г** | 15 722 | 1,922 | 0,01922 | 5,701 | 111100 | 6 |
| 18 | **б** | 13 411 | 1,639 | 0,01639 | 5,931 | 101011 | 6 |
| 19 | **з** | 13 235 | 1,618 | 0,01618 | 5,950 | 101010 | 6 |
| 20 | **ц** | 7 919 | 0,968 | 0,00968 | 6,691 | 1011111 | 7 |
| 21 | **ш** | 7 358 | 0,900 | 0,00900 | 6,797 | 1011110 | 7 |
| 22 | **ч** | 6 527 | 0,798 | 0,00798 | 6,970 | 1011100 | 7 |
| 23 | **х** | 5 682 | 0,695 | 0,00695 | 7,170 | 11110111 | 8 |
| 24 | **њ** | 5 273 | 0,645 | 0,00645 | 7,277 | 11110110 | 8 |
| 25 | **љ** | 4 104 | 0,502 | 0,00502 | 7,639 | 11110100 | 8 |
| 26 | **ћ** | 3 657 | 0,447 | 0,00447 | 7,805 | 10111011 | 8 |
| 27 | **ж** | 3 517 | 0,430 | 0,00430 | 7,862 | 10111010 | 8 |
| 28 | **ђ** | 2 367 | 0,289 | 0,00289 | 8,433 | 111101011 | 9 |
| 29 | **ф** | 2 155 | 0,263 | 0,00263 | 8,568 | 1111010101 | 10 |
| 30 | **џ** | 143 | 0,017 | 0,00017 | 12,482 | 1111010100 | 10 |
| | **Suma** | 818 001 | 100,000 | 1,00000 | | | |

*Tabela 4. Udział liter w korpusie (bez spacji) i ich kody Huffmana.*




*Rys. 2. Udział procentowy liter w korpusie.*

Rozkład jest bardzo nierównomierny: cztery samogłoski а, и, о, е to razem ok. 40% liter, a najrzadsze litery (ђ, ф, џ) mają poniżej 0,3% każda. Te różnice wykorzystuje kod Huffmana.

## 2.3. Entropia i kod Huffmana – jak działają (na małym przykładzie)

**Entropia** (C. Shannon, 1948) to średnia liczba bitów potrzebna na jeden znak:

$$H = -\Sigma\, p_i \cdot \log_2 p_i$$

Składnik $-\log_2 p_i$ to „idealna” długość kodu znaku i: im rzadszy znak, tym więcej niesie informacji i tym dłuższy może być jego kod. Entropia jest średnią z tych długości, ważoną częstością znaków.

**Algorytm Huffmana** (D. Huffman, 1952): (1) każdy znak to osobny węzeł z wagą równą liczbie wystąpień; (2) bierzemy dwa węzły o najmniejszych wagach i łączymy je w nowy węzeł o sumie wag; (3) powtarzamy, aż zostanie jeden węzeł (korzeń drzewa). Kod znaku to droga od korzenia do znaku: krok w lewo = 0, w prawo = 1. Częste znaki są łączone na końcu, więc leżą blisko korzenia i mają krótkie kody.

Przykład dla słowa **„абракадабра”** (11 liter): а × 5, б × 2, р × 2, д × 1, к × 1.

| Krok | Łączymy węzeł | waga | z węzłem | waga | Nowy węzeł (suma) |
|---|---|---|---|---|---|
| 1 | {д} | 1 | {к} | 1 | 2 |
| 2 | {б} | 2 | {р} | 2 | 4 |
| 3 | {д, к} | 2 | {б, р} | 4 | 6 |
| 4 | {а} | 5 | {д, к, б, р} | 6 | 11 |

*Tabela 5. Kolejne kroki algorytmu Huffmana dla słowa „абракадабра”.*

| Litera | Liczność | p | $-\log_2 p$ (ideał) | Kod Huffmana | Długość |
|---|---|---|---|---|---|
| **а** | 5 | 0,455 | 1,138 | 0 | 1 |
| **б** | 2 | 0,182 | 2,459 | 110 | 3 |
| **р** | 2 | 0,182 | 2,459 | 111 | 3 |
| **д** | 1 | 0,091 | 3,459 | 100 | 3 |
| **к** | 1 | 0,091 | 3,459 | 101 | 3 |

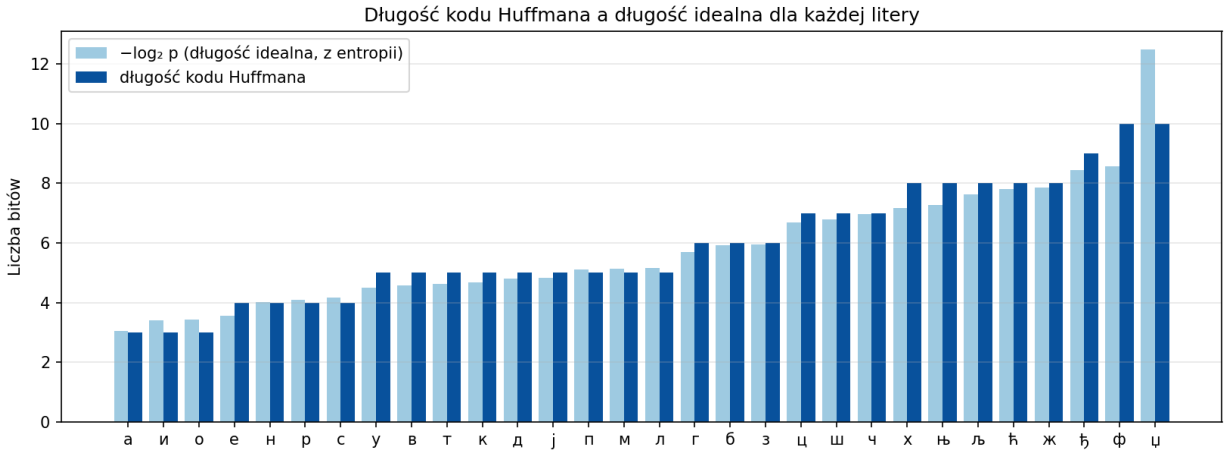
*Tabela 6. Kody Huffmana dla słowa „абракадабра”.*

Dla tego słowa entropia wynosi H = 2,040 bit/znak, a średnia długość kodu Huffmana L = 2,091 bit/znak. Kod o stałej długości potrzebowałby 3 bitów na znak (33 bitów na całe słowo), a Huffman potrzebuje 23 bitów.

## 2.4. Wyniki dla całego korpusu

| Wariant | n | H [bit] | $H_{max} = \log_2 n$ | Redund. | L Huffmana [bit] | L − H | H / L | Kod stały |
|---|---|---|---|---|---|---|---|---|
| same litery | 30 | 4,3024 | 4,9069 | 12,32% | 4,3368 | 0,0344 | 99,21% | 5 bit |
| litery + spacja | 31 | 4,2588 | 4,9542 | 14,04% | 4,2889 | 0,0301 | 99,30% | 5 bit |

*Tabela 7. Entropia a średnia długość kodu Huffmana. $H_{max}$ – entropia, gdyby wszystkie znaki były równie częste; redundancja = $1 - H/H_{max}$.*




*Rys. 3. Długość kodu Huffmana każdej litery w porównaniu z długością idealną $-\log_2 p$.*

**Wnioski.**

- Średnia długość kodu Huffmana (4,3368 bit) jest tylko o 0,0344 bitu większa od entropii (4,3024 bit). Efektywność kodu wynosi 99,21%, a warunek $H \le L < H + 1$ z twierdzenia Shannona o kodowaniu jest spełniony.

- Różnica $L - H$ bierze się stąd, że kod musi mieć całkowitą liczbę bitów, a $-\log_2 p$ zwykle nie jest liczbą całkowitą. Na wykresie słupki Huffmana są raz trochę wyższe, raz trochę niższe od ideału.
- Względem kodu o stałej długości (5 bitów) Huffman skraca zapis tekstu o 13,3%.
- Redundancja języka na poziomie pojedynczych liter wynosi ok. 12,3%: tyle „zbędnej” informacji wynika z nierównej częstości liter.
- Kod jest poprawny: zakodowany i zdekodowany korpus jest identyczny z oryginałem.

# 3. Laboratorium 3 – pokrycie tekstu, prawo Zipfa, graf sąsiedztwa

**Zadanie:** znaleźć wyrazy, które pokrywają 90% tekstu; sprawdzić prawo Zipfa; zbudować graf wyrazów sąsiadujących, zliczyć krawędzie wychodzące z każdego węzła i wyznaczyć rdzeń, czyli 100 wyrazów o największej liczbie sąsiadów.

## 3.1. Wyrazy pokrywające 90% tekstu

**W prostych słowach**

Ustawiamy wyrazy od najczęstszego i dodajemy ich udziały w tekście: „и” to 4,8% tekstu, „и” + „је” to już 8,8%, i tak dalej. Szukamy momentu, w którym suma przekroczy 90%. Liczba wyrazów do tego miejsca mówi, ile słów trzeba znać, żeby rozumieć 90% słów w tekście.

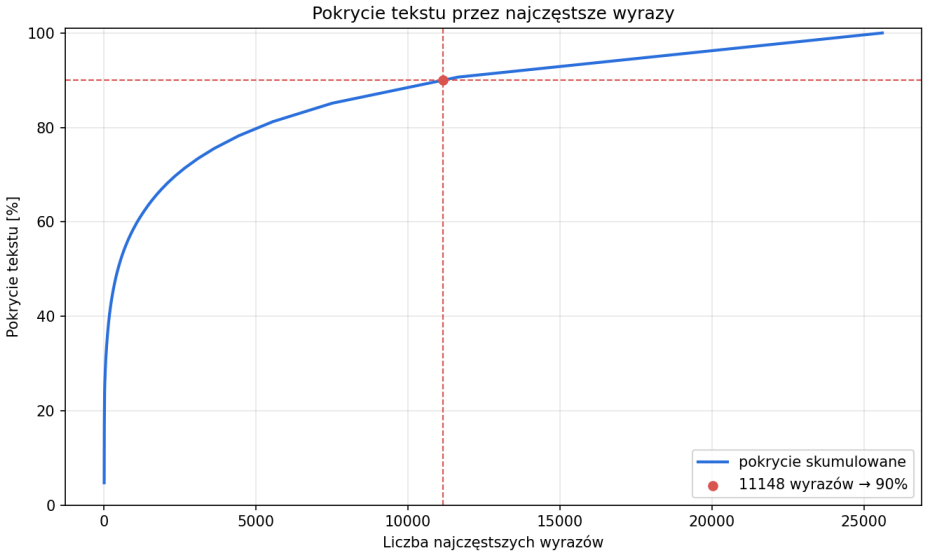
Korpus zawiera 149 373 wyrazów (tokenów) i 25 608 różnych wyrazów (typów). **Do pokrycia 90% tekstu potrzeba 11 148 najczęstszych wyrazów**, czyli 43,53% słownika. Aż 13 984 wyrazów (54,6%) występuje tylko raz.

| Pokrycie tekstu | Liczba najczęstszych wyrazów | Udział w słowniku |
|---|---|---|
| 25% | 19 | 0,07% |
| 50% | 455 | 1,78% |
| 75% | 3 482 | 13,60% |
| 80% | 5 091 | 19,88% |
| **90%** | 11 148 | 43,53% |
| 95% | 18 140 | 70,84% |
| 99% | 24 115 | 94,17% |

*Tabela 8. Liczba najczęstszych wyrazów potrzebna do pokrycia danej części tekstu.*

| Ranga | Wyraz | Liczność | Udział [%] | Skum. [%] | Ranga | Wyraz | Liczność | Udział [%] | Skum. [%] |
|---|---|---|---|---|---|---|---|---|---|
| 1 | и (i) | 7099 | 4,7525 | 4,7525 | 11 | а (a) | 1110 | 0,7431 | 21,5621 |
| 2 | је (jest) | 6083 | 4,0724 | 8,8249 | 12 | за (za / dla) | 1059 | 0,7090 | 22,2711 |
| 3 | у (w) | 5270 | 3,5281 | 12,3530 | 13 | који (który) | 748 | 0,5008 | 22,7719 |
| 4 | на (na) | 2440 | 1,6335 | 13,9865 | 14 | као (jako) | 726 | 0,4860 | 23,2579 |
| 5 | су (są) | 2273 | 1,5217 | 15,5082 | 15 | из (z) | 715 | 0,4787 | 23,7366 |
| 6 | се (się) | 2214 | 1,4822 | 16,9904 | 16 | до (do) | 652 | 0,4365 | 24,1730 |
| 7 | да (że / żeby) | 1537 | 1,0290 | 18,0193 | 17 | србије (Serbii) | 586 | 0,3923 | 24,5653 |
| 8 | године (roku) | 1473 | 0,9861 | 19,0054 | 18 | био (był) | 427 | 0,2859 | 24,8512 |
| 9 | од (od) | 1438 | 0,9627 | 19,9681 | 19 | по (po) | 343 | 0,2296 | 25,0808 |
| 10 | са (z) | 1271 | 0,8509 | 20,8190 | 20 | о (o) | 342 | 0,2290 | 25,3098 |

*Tabela 9. 20 najczęstszych wyrazów (z polskim znaczeniem). Pełna lista 11 148 wyrazów: wyniki/lab03/wyrazy_pokrycie_90.csv.*




*Rys. 4. Pokrycie tekstu przez najczęstsze wyrazy.*

**Wniosek:** krzywa rośnie bardzo szybko na początku: zaledwie 19 wyrazów (głównie spójniki i przyimki) pokrywa 25% tekstu, a 455 wyrazów – połowę. Potem rośnie powoli, bo pozostała część tekstu składa się z rzadkich wyrazów, m.in. różnych form odmiany tego samego słowa i nazw własnych.

## 3.2. Prawo Zipfa

**W prostych słowach**

George Zipf zauważył, że w każdym dużym tekście drugi najczęstszy wyraz występuje mniej więcej 2 razy rzadziej niż pierwszy, trzeci 3 razy rzadziej itd. Wzorem: f(r) ≈ C / r, gdzie r to miejsce w rankingu, a f to częstość. Na wykresie w skali logarytmicznej (log-log) taka zależność jest linią prostą o nachyleniu −1.

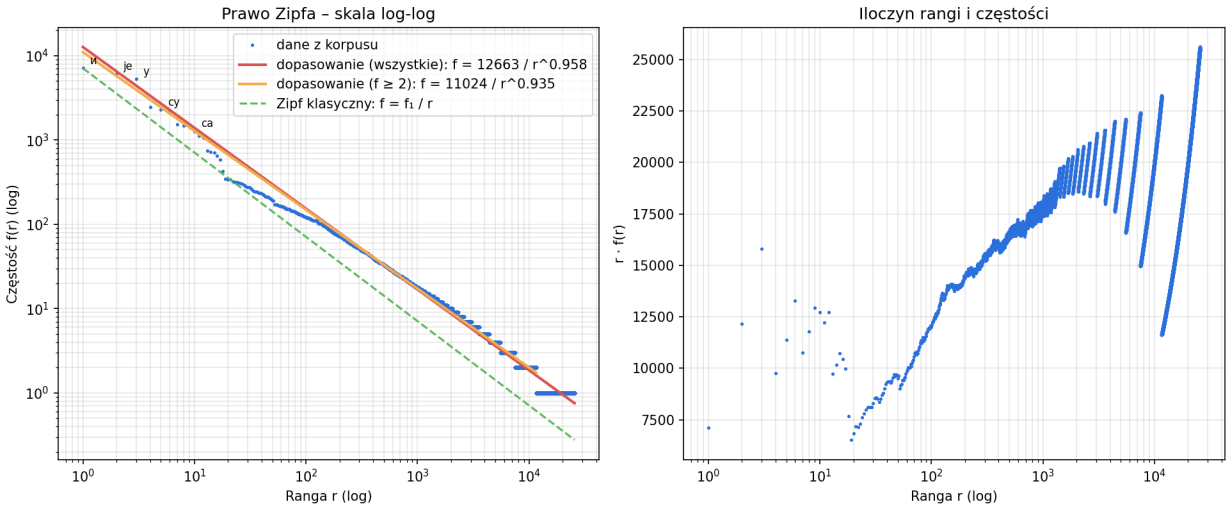
Ogólniej: $f(r) = C / r^s$. Po zlogarytmowaniu $\log f = \log C - s \cdot \log r$, więc s i C wyznaczyliśmy regresją liniową (metodą najmniejszych kwadratów, `numpy.polyfit`) na punktach (log r, log f).

| Dopasowanie | Wykładnik s | C | $R^2$ |
|---|---|---|---|
| wszystkie wyrazy (25 608) | **0,9584** | 12 663,4 | 0,9652 |
| bez hapaksów, f ≥ 2 (11 624) | 0,9351 | | |

*Tabela 10. Parametry prawa Zipfa dla korpusu ($R^2$ – jakość dopasowania, 1 = idealne).*

| Ranga r | Wyraz | f(r) | r · f(r) | f z prawa Zipfa ($f_1$ / r) |
|---|---|---|---|---|
| 1 | и (i) | 7099 | 7 099 | 7 099,0 |
| 2 | је (jest) | 6083 | 12 166 | 3 549,5 |
| 3 | у (w) | 5270 | 15 810 | 2 366,3 |
| 5 | су (są) | 2273 | 11 365 | 1 419,8 |
| 10 | са (z) | 1271 | 12 710 | 709,9 |
| 20 | о (o) | 342 | 6 840 | 354,9 |
| 50 | државе (państwa) | 190 | 9 500 | 142,0 |
| 100 | један (jeden) | 120 | 12 000 | 71,0 |
| 200 | друге (drugie / inne) | 72 | 14 400 | 35,5 |
| 500 | освојио (zdobył) | 33 | 16 500 | 14,2 |
| 1000 | војно (wojskowo) | 18 | 18 000 | 7,1 |

*Tabela 11. Sprawdzenie prawa Zipfa dla wybranych rang: iloczyn r · f(r) powinien być w przybliżeniu stały.*




*Rys. 5. Prawo Zipfa: częstość w funkcji rangi w skali log-log (po lewej) i iloczyn r · f(r) (po prawej).*

**Wniosek:** punkty układają się niemal na prostej ($R^2 = 0{,}965$), a wykładnik $s = 0{,}96$ jest bardzo bliski 1, więc **korpus spełnia prawo Zipfa**. Odchylenia widać dla kilku pierwszych rang (bardzo częste słowa funkcyjne и, у, је) i w ogonie, gdzie tysiące wyrazów mają tę samą małą częstość (poziome „schodki"). Lekkie spłaszczenie ($s < 1$) wynika z odmiany wyrazów w serbskim: србија, србије, србији, србију liczone są osobno. Ciekawostka: na 10 razy mniejszym korpusie (100 tys. znaków) wyszło $s = 0{,}68$. Prawo Zipfa dobrze widać dopiero na dużym tekście.

## 3.3. Graf wyrazów sąsiadujących i jego rdzeń

**W prostych słowach**

Każdy wyraz to punkt (węzeł). Jeśli dwa wyrazy choć raz stoją w tekście obok siebie, łączymy je kreską (krawędzią). Dla fragmentu „кнез лазар је подигао цркву" powstają krawędzie кнез–лазар, лазар–је, је–подигао, подигао–цркву. Wyraz, z którego wychodzi najwięcej krawędzi, sąsiaduje z największą liczbą różnych wyrazów, więc jest „centralny" dla języka. 100 takich wyrazów to rdzeń grafu.

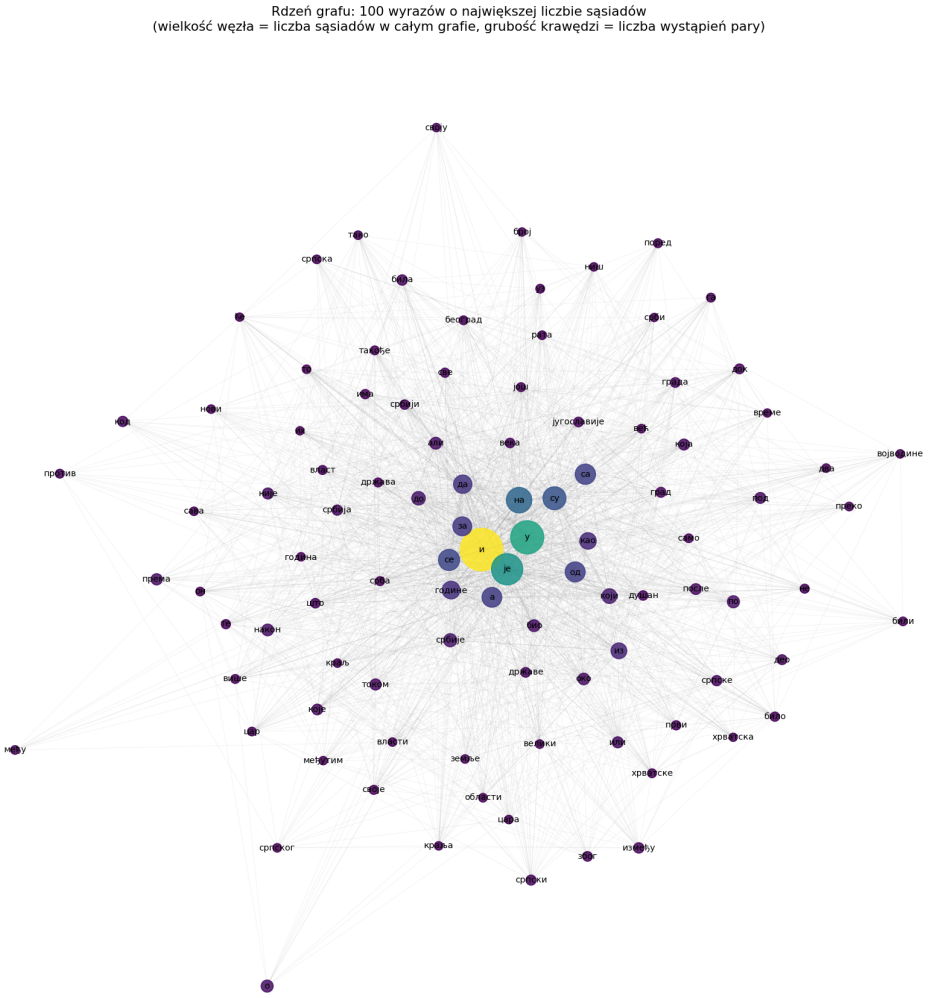
Krawędzie zliczyliśmy na dwa sposoby. **Krawędzie wychodzące** z wyrazu w to różne wyrazy występujące bezpośrednio po nim; **wchodzące** to wyrazy występujące bezpośrednio przed nim. Liczba wszystkich różnych sąsiadów to liczba krawędzi wychodzących z węzła w grafie nieskierowanym; według niej wyznaczyliśmy rdzeń. Graf zbudowano w `lab03_wyrazy_zipf_graf.py` (słowniki zbiorów sąsiadów, zapis do formatu GEXF biblioteką networkx).

| Wielkość | Wartość |
|---|---|
| Liczba węzłów (różnych wyrazów) | 25 608 |
| Liczba krawędzi skierowanych (a → b) | 99 265 |
| Liczba krawędzi nieskierowanych (a — b) | 95 855 |
| Średnia / mediana liczby sąsiadów | 7,49 / 2 |
| Maksymalna liczba sąsiadów | 6 800 (и (i)) |

*Tabela 12. Podstawowe parametry grafu sąsiedztwa.*

| Lp | Wyraz | Sąs. | Wych. | Wch. | Częst. | Lp | Wyraz | Sąs. | Wych. | Wch. | Częst. |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | и (i) | 6800 | 3986 | 3773 | 7099 | 51 | први (pierwszy) | 191 | 91 | 106 | 173 |
| 2 | у (w) | 4059 | 1695 | 2617 | 5270 | 52 | све (wszystko) | 188 | 82 | 114 | 152 |
| 3 | је (jest) | 3602 | 2435 | 1835 | 6083 | 53 | те (te / oraz) | 188 | 82 | 113 | 131 |
| 4 | на (na) | 2328 | 1029 | 1401 | 2440 | 54 | срба (Serbów) | 178 | 79 | 106 | 204 |
| 5 | су (są) | 1878 | 1183 | 938 | 2273 | 55 | своје (swoje) | 178 | 94 | 88 | 119 |
| 6 | се (się) | 1572 | 1080 | 681 | 2214 | 56 | власт (władza) | 177 | 110 | 78 | 173 |
| 7 | са (z) | 1433 | 703 | 765 | 1271 | 57 | не (nie) | 176 | 85 | 93 | 140 |
| 8 | од (od) | 1382 | 714 | 749 | 1438 | 58 | више (więcej) | 172 | 94 | 85 | 159 |
| 9 | а (a) | 1351 | 587 | 830 | 1110 | 59 | држава (państwo) | 171 | 86 | 97 | 153 |
| 10 | за (za / dla) | 1228 | 607 | 663 | 1059 | 60 | поред (obok / oprócz) | 170 | 78 | 94 | 114 |
| 11 | да (że / żeby) | 1149 | 487 | 704 | 1537 | 61 | још (jeszcze) | 169 | 79 | 98 | 151 |
| 12 | године (roku) | 1064 | 719 | 441 | 1473 | 62 | га (go) | 168 | 95 | 80 | 150 |
| 13 | као (jako) | 904 | 389 | 535 | 726 | 63 | против (przeciw) | 168 | 77 | 97 | 146 |
| 14 | из (z) | 814 | 346 | 484 | 715 | 64 | такође (także) | 166 | 94 | 77 | 141 |
| 15 | који (który) | 691 | 131 | 567 | 748 | 65 | хрватске (Chorwacji) | 165 | 84 | 87 | 123 |
| 16 | до (do) | 562 | 334 | 271 | 652 | 66 | уз (przy / wraz z) | 163 | 75 | 89 | 116 |
| 17 | србије (Serbii) | 521 | 279 | 260 | 586 | 67 | београд (Belgrad) | 161 | 70 | 104 | 157 |
| 18 | по (po) | 423 | 207 | 225 | 343 | 68 | само (tylko) | 159 | 86 | 80 | 110 |
| 19 | о (o) | 417 | 233 | 188 | 342 | 69 | међу (pośród) | 156 | 63 | 93 | 118 |
| 20 | али (ale) | 402 | 104 | 305 | 341 | 70 | он (on) | 154 | 61 | 98 | 165 |
| 21 | био (był) | 397 | 221 | 189 | 427 | 71 | били (byli) | 154 | 81 | 78 | 145 |
| 22 | након (po) | 390 | 163 | 234 | 317 | 72 | српска (serbska) | 154 | 69 | 93 | 127 |
| 23 | око (około) | 379 | 202 | 197 | 317 | 73 | преко (przez) | 154 | 83 | 79 | 101 |
| 24 | према (według / ku) | 347 | 164 | 187 | 238 | 74 | рата (wojny) | 153 | 112 | 45 | 171 |
| 25 | током (podczas) | 336 | 139 | 207 | 268 | 75 | цар (car) | 153 | 79 | 83 | 167 |
| 26 | или (lub) | 328 | 169 | 186 | 211 | 76 | велики (wielki) | 153 | 51 | 104 | 151 |
| 27 | није (nie jest) | 326 | 156 | 172 | 276 | 77 | области (obwodu / dziedziny) | 152 | 86 | 74 | 114 |
| 28 | која (która) | 324 | 66 | 259 | 325 | 78 | два (dwa) | 151 | 87 | 69 | 128 |
| 29 | под (pod) | 318 | 128 | 193 | 280 | 79 | тако (tak) | 149 | 34 | 119 | 142 |
| 30 | после (po) | 314 | 152 | 165 | 243 | 80 | српског (serbskiego) | 149 | 50 | 103 | 137 |
| 31 | које (które) | 305 | 67 | 240 | 307 | 81 | већ (już) | 149 | 68 | 88 | 133 |
| 32 | била (była) | 277 | 173 | 114 | 290 | 82 | нови (nowy) | 148 | 41 | 110 | 171 |
| 33 | између (między) | 276 | 119 | 160 | 213 | 83 | то (to) | 146 | 91 | 70 | 216 |
| 34 | код (u / przy) | 266 | 135 | 138 | 197 | 84 | сава (Sawa) | 146 | 73 | 80 | 164 |
| 35 | српске (serbskiej) | 262 | 100 | 172 | 242 | 85 | цара (cara) | 145 | 77 | 71 | 163 |
| 36 | србија (Serbia) | 260 | 113 | 164 | 277 | 86 | земље (kraju / ziemi) | 145 | 79 | 75 | 107 |
| 37 | српски (serbski) | 252 | 118 | 142 | 237 | 87 | власти (władzy) | 144 | 87 | 59 | 128 |
| 38 | град (miasto) | 245 | 126 | 139 | 237 | 88 | војводине (Wojwodiny) | 144 | 82 | 65 | 126 |
| 39 | део (część) | 237 | 142 | 102 | 223 | 89 | краљ (król) | 143 | 63 | 89 | 168 |
| 40 | док (podczas gdy) | 233 | 40 | 197 | 228 | 90 | година (rok / lat) | 143 | 91 | 63 | 137 |
| 41 | града (miasta) | 230 | 116 | 123 | 233 | 91 | краља (króla) | 142 | 65 | 80 | 143 |
| 42 | државе (państwa) | 228 | 126 | 108 | 190 | 92 | ниш (Nisz) | 139 | 75 | 71 | 130 |
| 43 | због (z powodu) | 221 | 97 | 126 | 151 | 93 | својој (swoją) | 137 | 66 | 73 | 104 |
| 44 | југославије (Jugosławii) | 219 | 128 | 99 | 212 | 94 | међутим (jednak) | 137 | 64 | 76 | 81 |
| 45 | што (co) | 212 | 49 | 168 | 312 | 95 | број (liczba) | 135 | 82 | 56 | 122 |
| 46 | века (wieku) | 212 | 163 | 58 | 246 | 96 | срби (Serbowie) | 131 | 65 | 75 | 130 |
| 47 | душан (Duszan) | 208 | 81 | 136 | 258 | 97 | ће (będzie) | 131 | 83 | 51 | 129 |
| 48 | србији (w Serbii) | 206 | 159 | 50 | 300 | 98 | их (ich) | 131 | 66 | 70 | 120 |
| 49 | има (ma) | 198 | 106 | 97 | 162 | 99 | хрватска (Chorwacja) | 130 | 57 | 82 | 112 |
| 50 | било (było) | 197 | 122 | 84 | 202 | 100 | време (czas) | 129 | 112 | 20 | 157 |

*Tabela 13. Rdzeń grafu – 100 wyrazów o największej liczbie sąsiadów (Sąs. – różni sąsiedzi, Wych./Wch. – krawędzie wychodzące/wchodzące, Częst. – liczba wystąpień).*


Rdzeń grafu: 100 wyrazów o największej liczbie sąsiadów
(wielkość węzła = liczba sąsiadów w całym grafie, grubość krawędzi = liczba wystąpień pary)
и
у
је
на
су
за
да
се
од
са
Београд
Србија
Србије
Србији
Србије
Србије
Србије

- Wyrazy rdzenia to 35,1% wszystkich wyrazów tekstu, a 88 ze 100 z nich należy też do 100 najczęstszych wyrazów: im częstszy wyraz, tym więcej ma sąsiadów.
- Ranking według samych krawędzi wychodzących (skierowanych) daje rdzeń wspólny z powyższym w 83 wyrazach na 100, więc wybór sposobu liczenia krawędzi niewiele zmienia.
- Rozkład liczby sąsiadów jest potęgowy (prosta w skali log-log): mediana to 2 sąsiadów, a maksimum to kilka tysięcy. Taki graf nazywa się **bezskalowym**: kilka węzłów-hubów łączy całą sieć, podobnie jak w sieciach społecznych czy w internecie.

# 4. Laboratorium 4 – analiza semantyczna: klasyfikator rzeczowników oparty na sieci Kohonena

**Zadanie:** opracować klasyfikator semantyczny rzeczowników oparty na sieci Kohonena. Przeanalizować co najmniej 1000 rzeczowników na podstawie ich powiązań ze 100 czasownikami przechodnimi: każdy rzeczownik to wektor o 100 składowych, z których każda zawiera liczbę wystąpień frazy VO (czasownik + jego dopełnienie bliższe). Sieć ma mieć 50 neuronów. Oczekuje się, że sieć spontanicznie wytworzy klastry rzeczowników ze wspólnego pola semantycznego. Należy sprawdzić, czy klastry są logicznie uzasadnione i jednorodne, ile pól semantycznych powstało i czy są neurony, które niczego się nie nauczyły.

**W prostych słowach**

Rzeczownik można poznać po tym, z jakimi czasownikami się łączy. „Chleb”, „mięso” i „ser” się *je*, „wodę”, „kawę” i „wino” się *pije*, a „mecz” i „rolę” się *gra*. Zapisujemy więc dla każdego rzeczownika 100 liczb: ile razy był dopełnieniem każdego ze 100 czasowników. Rzeczowniki z jednego pola znaczeniowego mają podobne listy liczb. Sieć Kohonena to 50 „szufladek”, które – bez żadnej podpowiedzi – uczą się zbierać podobne rzeczowniki do jednej szufladki, a podobne szufladki układać obok siebie.

## 4.1. Korpus do analizy semantycznej

Korpus z laboratorium 1 (ok. 150 tys. wyrazów, głównie historia i geografia Serbii) dawał tylko ok. 900 rzeczowników będących dopełnieniem 100 czasowników przechodnich, w dodatku większość z jednym wystąpieniem – za mało na 1000 wektorów i zbyt jednorodnie tematycznie, żeby powstały różne pola znaczeniowe. Dlatego skrypt `lab04_pobieranie.py` pobrał z serbskiej Wikipedii dodatkowe 474 artykułów (ok. 8 mln znaków) z różnych dziedzin: jedzenie i napoje, zwierzęta, rośliny, ubrania, budynki, transport, muzyka i sztuka, medycyna, sport, nauka i technika, gospodarka i polityka, wojsko, przyroda, rodzina. Do analizy użyto obu korpusów razem.

| Dziedzina | Artykułów | Przykłady |
|---|---|---|
| gospodarka i polityka | 59 | Новац, Банка, Привреда, Трговина, Порез, Евро, Фабрика, Индустрија, Рударство, Устав, Скупштина, Избори, Демократија, Суд, Полиција, Уједињене нације,… |
| muzyka i sztuka | 57 | Музика, Гитара, Клавир, Виолина, Бубањ, Опера, Песма, Оркестар, Рок, Џез, Сликарство, Филм, Фотографија, Плес, Позоришна представа, Роман, Поезија, Књ… |
| jedzenie i napoje | 51 | Храна, Хлеб, Сир, Месо, Млеко, Вино, Пиво, Кафа, Чај, Шећер, Со, Јаје, Мед, Поврће, Кромпир, Пшеница, Кукуруз, Пиринач, Јабука, Грожђе, Парадајз, Чоко… |
| zwierzęta | 42 | Пас, Мачка, Домаћи коњ, Козе, Свиња, Кокошка, Вук, Медведи (породица), Лисица, Јелени, Зец, Лав, Тигар, Орао, Птице, Рибе, Змије, Пчеле, Мрави, Инсект… |
| sport | 37 | Спорт, Фудбал, Кошарка, Одбојка, Рукомет, Тенис, Ватерполо, Пливање, Атлетика, Шах, Бокс, Скијање, Светско првенство у фудбалу, Новак Ђоковић, Фудбалс… |
| budynki i miasto | 36 | Кућа, Мост, Тврђава, Џамија, Архитектура, Пут, Улица, Град, Село, Школа, Болница, Позориште, Музеј, Библиотека, Стадион, Лука, Motorni benzin, Ракови,… |
| nauka i technika | 35 | Рачунар, Телефон, Мобилни телефон, Интернет, Софтвер, Електрична енергија, Машина, Робот, Нафта, Угаљ, Гвожђе, Бакар, Челик, Пластика, Стакло, Вода, В… |
| medycyna i ciało | 29 | Медицина, Болест, Лек, Срце, Мозак, Крв, Кост, Кожа, Око, Грип, Рак (болест), Вакцина, Антибиотик, Хирургија, Шећерна болест, Пандемија ковида 19, Здр… |
| transport | 27 | Аутомобил, Аутобус, Воз, Железница, Авион, Брод, Бицикл, Мотоцикл, Камион, Трамвај, Метро, Подморница, Хеликоптер, Ракета, Саобраћај, Веслање (спорт),… |
| przyroda i geografia | 27 | Река, Језеро, Море, Океан, Планина, Острво, Пустиња, Клима, Киша, Снег, Ветар, Земљотрес, Вулкан, Песак, Сунце, Хемија, Планктон, Циклон, Морски сисар… |
| rodzina i życie | 25 | Породица, Брак, Дете, Мајка, Отац, Образовање, Учитељ, Запослење, Божић, Ускрс, Венчање, Игра, Играчка, Литургија, Руска Империја, Српски народни кале… |
| rośliny | 21 | Биљке, Дрво, Шума, Храст, Цвет, Ружа, Траве, Пољопривреда, Врт, Семе, Лист, Гљиве, Ратарство, Скривеносеменице, Кулинарство, Перм (периода), Бошњаци, … |
| ubrania i przedmioty | 14 | Одећа, Шешир, Накит, Злато, Сребро, Намештај, Сат, Текстил, Вуна, Свила, Прометијум, Тантал, Папир, Радон… |
| wojsko | 14 | Војска, Оружје, Пушка, Топ, Тенк, Ратна морнарица, Ратно ваздухопловство, Битка, Мач, Штит, Барут, Бомба, Стогодишњи рат, Наполеонови ратови… |

*Tabela 14. Dziedziny artykułów korpusu dodatkowego.*

## 4.2. Analiza składniowa i frazy VO

Żeby wiedzieć, który rzeczownik jest dopełnieniem którego czasownika, potrzebna jest analiza gramatyczna zdań. Użyto biblioteki **stanza** (Stanford NLP) z modelem języka serbskiego (treebank UD Serbian-SET, standard Universal Dependencies). Skrypt `lab04_parsowanie.py`:

1. wczytuje tekst surowy (z interpunkcją, bo potrzebne są granice zdań) i dzieli go na porcje, przetwarzane równolegle w kilku procesach,
2. zamienia cyrylicę na łacinkę, bo model był uczony na serbskiej łacince (odpowiedniość liter jest 1:1, np. љ → lj, њ → nj, џ → dž),
3. dla każdego wyrazu ustala część mowy, lemat (formę podstawową) i wyraz nadrzędny wraz z relacją, np. *obj* = dopełnienie bliższe,
4. przepisuje wynik z powrotem na cyrylicę i zapisuje go do plików .tsv.gz w folderze dane/.

Wynik: 74 066 zdań, 1 526 987 tokenów i **37 243 fraz VO** (czasownik → dopełnienie rzeczownikowe). Przykład: w zdaniu „Кнез Лазар је подигао цркву и водио војску” parser znajduje frazy VO(подићи, црква) i VO(водити, војска). Dzięki lematyzacji formy цркву, цркве, црквом liczą się jako jeden rzeczownik црква. Liczone są też dopełnienia współrzędne: w „купио хлеб и млеко” dopełnieniami są oba rzeczowniki.

## 4.3. Wybór 100 czasowników przechodnich i 1000 rzeczowników

1. Dla każdego czasownika liczymy, ile razy ma dopełnienie rzeczownikowe.
2. Czasownik uznajemy za **przechodni**, jeśli dopełnienie ma w co najmniej 20% wystąpień (odrzuca to błędy parsera, np. постати – stać się: „постао је краљ”).
3. Pomijamy czasowniki posiłkowe i modalne (бити, хтети, моћи, морати, требати).
4. Bierzemy **100 czasowników** o największej liczbie fraz VO, a potem **1000 rzeczowników**, które najczęściej są dopełnieniem tych czasowników.

| Lp | Czasownik | VO | Lp | Czasownik | VO |
|---|---|---|---|---|---|
| 1 | имати (mieć) | 4450 | 51 | обављати (wykonywać) | 101 |
| 2 | укључивати (obejmować / włączać) | 966 | 52 | подржавати | 100 |
| 3 | користити (używać) | 834 | 53 | произвести | 99 |
| 4 | представљати (przedstawiać / stanowić) | 757 | 54 | мењати (zmieniać) | 99 |
| 5 | садржати (zawierać) | 700 | 55 | увести (wprowadzić) | 98 |
| 6 | чинити (stanowić / czynić) | 618 | 56 | обезбеђивати | 97 |
| 7 | обухватати (obejmować) | 562 | 57 | повећати | 93 |
| 8 | добити (otrzymać) | 427 | 58 | смањивати | 92 |
| 9 | дати (dać) | 334 | 59 | дефинисати | 92 |
| 10 | немати (nie mieć) | 316 | 60 | прихватити (przyjąć) | 90 |
| 11 | освојити (zdobyć) | 282 | 61 | повезивати (łączyć) | 90 |
| 12 | носити (nosić) | 254 | 62 | успоставити (ustanowić) | 89 |
| 13 | давати (dawać) | 246 | 63 | организовати (organizować) | 89 |
| 14 | формирати (utworzyć) | 224 | 64 | заузети (zająć) | 87 |
| 15 | добијати (otrzymywać) | 207 | 65 | послати (wysłać) | 86 |
| 16 | омогућавати | 198 | 66 | нудити (oferować) | 84 |
| 17 | захтевати | 198 | 67 | открити | 83 |
| 18 | донети (przynieść / uchwalić) | 193 | 68 | покривати (pokrywać) | 82 |
| 19 | изазвати (wywołać) | 193 | 69 | доживети (przeżyć / doznać) | 82 |
| 20 | стварати | 192 | 70 | обезбедити | 82 |
| 21 | пружати (stawiać / udzielać) | 178 | 71 | делити | 81 |
| 22 | створити (stworzyć) | 168 | 72 | задржати (zachować) | 81 |
| 23 | изазивати (wywoływać) | 168 | 73 | правити | 81 |
| 24 | развити | 163 | 74 | држати (trzymać) | 80 |
| 25 | водити (prowadzić) | 159 | 75 | покренути (wszcząć / uruchomić) | 80 |
| 26 | значити | 158 | 76 | одиграти | 79 |
| 27 | означавати | 146 | 77 | поставити (postawić / ustanowić) | 78 |
| 28 | узроковати | 143 | 78 | градити | 78 |
| 29 | поседовати (posiadać) | 135 | 79 | контролисати | 78 |
| 30 | вршити (pełnić / sprawować) | 133 | 80 | видети | 78 |
| 31 | омогућити | 133 | 81 | усвојити (przyjąć / uchwalić) | 77 |
| 32 | доносити (przynosić / uchwalać) | 131 | 82 | објавити | 76 |
| 33 | основати (założyć) | 127 | 83 | написати | 75 |
| 34 | направити | 126 | 84 | оставити (zostawić) | 74 |
| 35 | стећи (zdobyć / nabyć) | 118 | 85 | описивати | 74 |
| 36 | тражити (szukać / żądać) | 115 | 86 | спречавати | 74 |
| 37 | остварити (osiągnąć) | 115 | 87 | штитити (chronić) | 73 |
| 38 | преузети (przejąć) | 115 | 88 | започети (rozpocząć) | 72 |
| 39 | производити | 113 | 89 | наћи (znaleźć) | 72 |
| 40 | одређивати | 111 | 90 | пружити (stawić / udzielić) | 71 |
| 41 | заузимати (zajmować) | 110 | 91 | регулисати | 71 |
| 42 | извршити (wykonać / dokonać) | 110 | 92 | одражавати | 71 |
| 43 | изгубити (stracić) | 110 | 93 | преносити | 71 |
| 44 | пратити (śledzić / towarzyszyć) | 109 | 94 | следити | 70 |
| 45 | показивати | 109 | 95 | износити (wynosić) | 69 |
| 46 | подразумевати (oznaczać / zakładać) | 108 | 96 | напустити (opuścić) | 69 |
| 47 | играти | 106 | 97 | описати | 69 |
| 48 | повећавати | 105 | 98 | приказивати | 68 |
| 49 | постићи (osiągnąć) | 104 | 99 | проширити (rozszerzyć) | 67 |
| 50 | одржавати (utrzymywać) | 102 | 100 | губити | 67 |

*Tabela 15. 100 wybranych czasowników przechodnich (VO – liczba fraz czasownik–dopełnienie rzeczownikowe).*

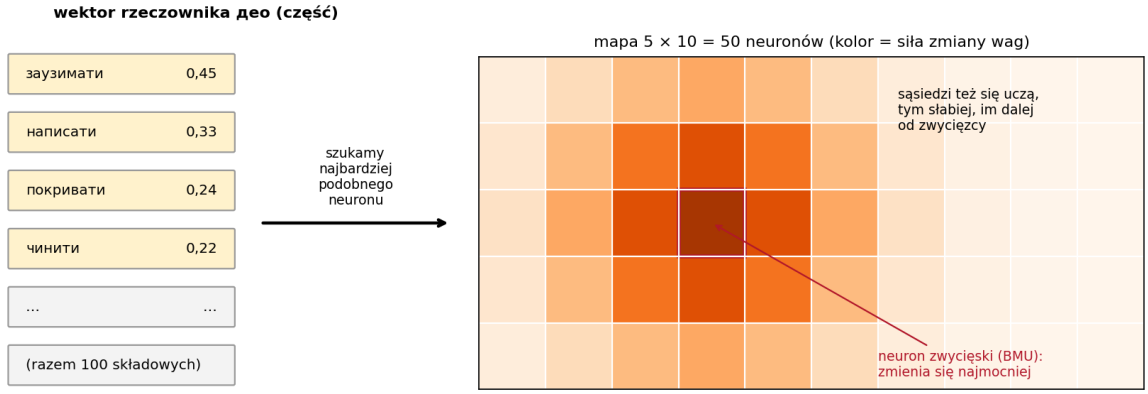
Wybrane rzeczowniki mają od 4 do 280 fraz VO (mediana 8) i łączą się średnio z 6,9 różnymi czasownikami. Najczęstsze: улога (280), део (189), право (138), број (138), утицај (136), име (133), систем (121), место (114), облик (106), функција (92), врста (92), способност (91), површина (86), титула (83), власт (76), назив (73), количина (71), група (69), могућност (66), одлука (66), вредност (65), медаља (65), структура (63), држава (61), подршка (61), однос (60), веза (58), значај (57), већина (56), статус (56). Pełna lista 1000 rzeczowników jest w `wyniki/lab04/rzeczowniki.csv`.

## 4.4. Zbiór treningowy – wektory o 100 składowych

Każdy rzeczownik zamieniamy na wektor $x = (x_1, \ldots, x_{100})$, gdzie $x_j$ to liczba wystąpień frazy VO złożonej z j-tego czasownika i tego rzeczownika. Przykład – wektor rzeczownika **део** ma 41 niezerowych składowych, największe: чинити = 33, представљати = 20, имати = 18, обухватати = 17, заузимати = 17, садржати = 10, користити = 7, написати = 7, укључивати = 4, добити = 4; pozostałe składowe to zera. Cały zbiór treningowy to macierz 1000 × 100 (`wyniki/lab04/zbior_treningowy.csv`). Przed uczeniem wektory przygotowano w dwóch krokach:

- **log(1 + x)** – zmniejsza wpływ bardzo częstych fraz, żeby jedna fraza nie zdominowała wektora,
- **waga IDF czasownika** = log(1000 / liczba rzeczowników łączących się z tym czasownikiem) – czasowniki łączące się prawie ze wszystkim (имати – mieć, представљати – stanowić, садржати – zawierać) niewiele mówią o znaczeniu rzeczownika, więc dostają mniejszą wagę niż czasowniki wybiórcze (освојити – zdobyć, изазвати – wywołać). Bez tej wagi połowa neuronów była zdominowana przez имати i zawierała przypadkowe mieszaniny rzeczowników,
- **normalizacja do długości 1** – porównujemy „profil” czasowników, a nie to, jak często rzeczownik w ogóle występuje (rzadki i częsty rzeczownik z tym samym profilem są podobne).

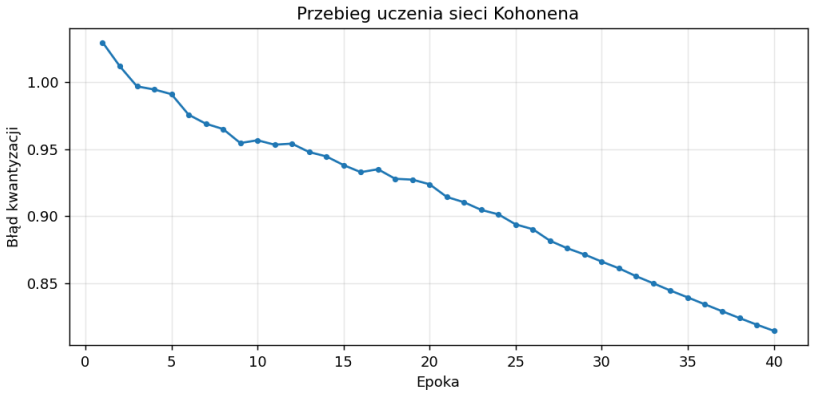
## 4.5. Sieć Kohonena – budowa i uczenie




*Rys. 8. Jeden krok uczenia sieci Kohonena: wektor rzeczownika (po lewej) przyciąga neuron zwycięski i, słabiej, jego sąsiadów (po prawej).*

Sieć zaimplementowano samodzielnie w numpy (klasa `KohonenSOM` w `lab04_kohonen.py`). Parametry i algorytm:

- **50 neuronów** ułożonych w siatkę 5 × 10; każdy neuron ma wektor wag $w \in R^{100}$,
- inicjalizacja: małe losowe wagi (rozkład jednostajny 0–0,1, stałe ziarno – wynik powtarzalny),
- 40 epok; w każdej epoce wszystkie 1000 wektorów w losowej kolejności. Dla wektora x szukamy neuronu zwycięskiego (BMU) – o najmniejszej odległości $\|x - w\|$,
- aktualizacja wag: $w \leftarrow w + \eta(t) \cdot h(t) \cdot (x - w)$, gdzie $h = \exp(-d^2 / 2\sigma(t)^2)$ to „siła sąsiedztwa”, a d to odległość neuronu od zwycięzcy na siatce,
- współczynnik uczenia η maleje z 0,5 do 0,01, a promień sąsiedztwa σ z 5 do 0,5: najpierw mapa układa się z grubsza, potem dopracowuje szczegóły,
- ocena: błąd kwantyzacji (średnia odległość wektora od jego BMU) i błąd topograficzny (odsetek wektorów, których dwa najlepsze neurony nie sąsiadują na siatce).




*Rys. 9. Spadek błędu kwantyzacji w trakcie uczenia.*

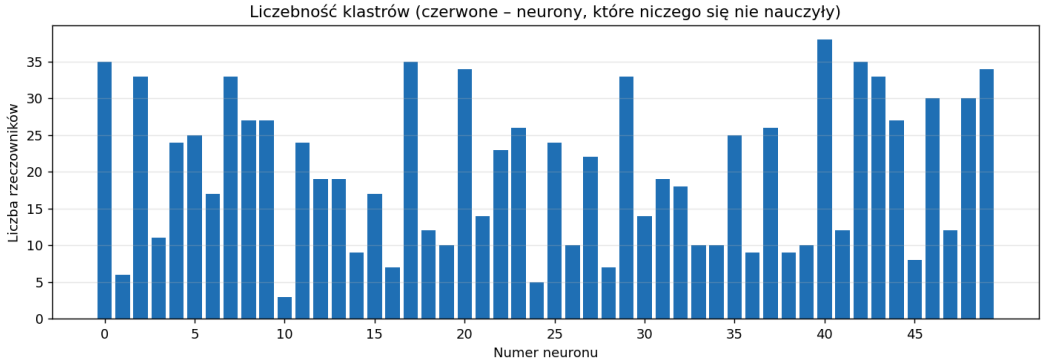
Po uczeniu: błąd kwantyzacji 0,814, błąd topograficzny 19,2%.

## 4.6. Wynik – klastry rzeczowników

Na mapie (rys. niżej) każdy kwadrat to jeden neuron: numer i liczba rzeczowników, na niebiesko czasownik o największej wadze, na czerwono najczęstsze rzeczowniki, które do niego trafiły, na zielono pole semantyczne (nasza interpretacja). Tło to U-macierz: jasne pola – neuron podobny do sąsiadów, ciemne – granica między skupieniami.




*Rys. 10. Mapa Kohonena – 1000 rzeczowników na 50 neuronach (siatka 5 × 10 narysowana pionowo; w każdym neuronie 5 najczęstszych rzeczowników).*




*Rys. 11. Liczba rzeczowników w każdym neuronie.*

| # | N | Spójn. | Dominujące czasowniki | Pole semantyczne | Rzeczowniki (najczęstsze) |
|---|---|---|---|---|---|
| 0 | 35 | 0,468 | носити, користити, имати, добити | przedmioty noszone: broń, oznaki, rękawice *(niejednorodny)* | назив, опрема, корен, тежина, топ, оружје, ознака, крв, кост, застава, јаје, лист … |
| 1 | 6 | 0,220 | носити, пружати, дефинисати, користити | – | број, храна, играч, богатство, воља, терет |
| 2 | 33 | 0,374 | пружати, пружити, имати, представљати | pomoc, wsparcie, ochrona | могућност, подршка, заштита, енергија, помоћ, извор, отпор, доказ, услуга, вид, мера, корист … |
| 3 | 11 | 0,570 | доживети, пружати, изазвати, донети | etapy dziejów: rozkwit i upadek | пораз, пад, револуција, година, напредак, процват, врхунац, адаптација, разарање, успон, издање |
| 4 | 24 | 0,405 | изазвати, узроковати, смањивати, изазивати | skutki negatywne: choroby, szkody, straty | промена, болест, потреба, губитак, потешкоћа, случај, повлачење, сукоб, загађење, казна, депресија, окружење … |
| 5 | 25 | 0,515 | изазивати, изазвати, узроковати, показивати | skutki negatywne: choroby, szkody, straty | проблем, ефекат, реакција, осећај, оштећење, повећање, поремећај, смрт, струја, бол, учинак, повреда … |
| 6 | 17 | 0,296 | узроковати, изазивати, омогућити, омогућавати | procesy i zmiany | употреба, развој, кретање, стварање, смањење, појава, покрета, формирање, продукција, пораст, канцер, инфекција … |
| 7 | 33 | 0,241 | омогућити, омогућавати, укључивати, обухватати | czynności i działania | примена, рад, приступ, корак, коришћење, истраживање, класификација, ширење, пролаз, увид, увођење, превоз … |
| 8 | 27 | 0,286 | извршити, вршити, обављати, започети | działania wykonywane: ataki, reformy, służba | утицај, функција, процес, инвазија, задатак, напад, дужност, притисак, реформа, служба, подела, обрада … |
| 9 | 27 | 0,348 | водити, обављати, покренути, извршити | wojna, polityka, walka (prowadzić) | порекло, посао, политика, живот, рат, реч, војска, слобода, операција, борба, брига, преговор … |
| 10 | 3 | 0,376 | носити, користити, дефинисати, имати | – | дете, светлост, батерија |
| 11 | 24 | 0,308 | дефинисати, развити, користити, усвојити | teorie i systemy pojęć | клима, језик, теорија, музика, концепт, календар, појам, принцип, стратегија, позориште, специфичност, станица … |
| 12 | 19 | 0,270 | прихватити, преузети, пружати, усвојити | władza, odpowiedzialność, propozycje | власт, услов, идеја, одговорност, предлог, воћство, обавеза, мир, евро, понуда, учешће, чињеница … |
| 13 | 19 | 0,272 | донети, доносити, остварити, освојити | decyzje i akty prawne | одлука, закон, победа, култура, циљ, пласман, декларација, резолуција, победа, срећа, остатка, акт … |
| 14 | 9 | 0,349 | постићи, изазвати, показивати, донети | osiągnięcia: gole, sukcesy | гол, успех, погодак, успеха, успјех, васкрсење, жеља, проводљивост, несигурност |
| 15 | 17 | 0,369 | показивати, изазивати, повећавати, узроковати | cechy i przejawy zachowania | степен, ефект, варијација, сличност, симптом, понашање, интересовање, континуитет, утицаја, ширина, дубина, разноликост … |
| 16 | 7 | 0,540 | спречавати, укључивати, обухватати, имати | – | раст, повратак, мрља, клизање, рефлексија, дуга, режим |
| 17 | 35 | 0,285 | укључивати, обухватати, значити, имати | mieszany: przyroda i różne obiekty *(niejednorodny)* | животиња, почетак, реп, аспект, објект, море, долина, пракса, представник, организам, лек, кукуруз … |
| 18 | 12 | 0,210 | обухватати, организовати, укључивати, вршити | mieszany: działalność i wydarzenia *(niejednorodny)* | догађај, биљак, размена, делатност, жена, дистрибуција, путовање, каријера, убиство, краљ, коњаник, лов |
| 19 | 10 | 0,389 | основати, организовати, водити, покренути | wydarzenia organizowane: gry, wystawy, referenda | игра, суд, такмичење, покрет, бог, изложба, одбрана, референдум, протест, пројект |
| 20 | 34 | 0,278 | користити, означавати, представљати, обухватати | metody, techniki, narzędzia | метод, техника, термин, мотор, симбол, дрво, технологија, мрава, рука, израз, нога, наука … |
| 21 | 14 | 0,197 | користити, развити, увести, укључивати | systemy, programy, modele | систем, програм, инструмент, стил, верзија, бојати, брод, образац, тема, модел, тенк, процедура … |
| 22 | 23 | 0,346 | написати, објавити, освојити, користити | teksty i dzieła | део, правило, историја, књига, писмо, извештај, опера, серија, метал, дело, напор, роман … |
| 23 | 26 | 0,455 | освојити, доносити, написати, заузети | trofea i zawody sportowe | титула, медаља, град, награда, првенство, пут, област, турнир, крај, бод, тржиште, злато … |
| 24 | 5 | 0,421 | освојити, повећавати, држати, имати | – | лопта, круна, монопол, час, канџа |
| 25 | 24 | 0,407 | повећавати, повећати, смањивати, имати | wielkości, które rosną i maleją | способност, брзина, производња, граница, ризик, дужина, активност, опасност, температура, стопа, шанса, чврстоћа … |
| 26 | 10 | 0,473 | износити, повећавати, имати, поставити | jednostki miary i liczebność | становник, тона, сило, деца, долар, резерва, хектар, бруто, метар, покрајина |
| 27 | 22 | 0,286 | поставити, представљати, укључивати, имати | mieszany: ludzie, instytucje, normy *(niejednorodny)* | човек, син, стандард, институција, уметност, потенцијал, сцена, питање, ограничење, оквир, особа, локација … |
| 28 | 7 | 0,293 | основати, успоставити, представљати, поставити | porozumienia i związki | породица, обичај, контакт, унија, споразум, суверенитет, сарадња |
| 29 | 33 | 0,444 | основати, успоставити, створити, чинити | państwa i instytucje zakładane | царство, члан, насеље, црква, колонија, индустрија, школа, скупштина, република, друштво, клуб, савез … |
| 30 | 14 | 0,362 | садржати, користити, производити, имати | materiały i substancje wytwarzane | материјал, ресурс, супстанац, гас, фреквенција, лук, барут, кућа, парадајз, чоколада, једар, мотив … |
| 31 | 19 | 0,173 | садржати, користити, производити, имати | mieszany: rodzaje i sposoby *(niejednorodny)* | врста, низ, начин, пар, тело, вино, топлота, тип, мноштво, пример, фока, мелодија … |
| 32 | 18 | 0,174 | давати, оставити, напустити, дати | mieszany: dźwięki, obrazy, ślady *(niejednorodny)* | звук, слика, траг, последица, острво, план, сигнал, терен, мишљење, правац, ток, мисија … |
| 33 | 10 | 0,363 | заузети, освојити, добити, добијати | miejsca i pozycje zajmowane | место, земља, позиција, став, глас, важност, регион, тврђава, поседа, курс |
| 34 | 10 | 0,233 | стећи, проширити, поседовати, добити | role i terytoria zdobywane | улога, територија, утакмица, моћ, положај, меч, опсег, фокус, обим, ван |

| # | N | Spójn. | Dominujące czasowniki | Pole semantyczne | Rzeczowniki (najczęstsze) |
|---|---|---|---|---|---|
| 35 | 25 | 0,337 | поседовати, имати, повећати, нематu | właściwości i cechy | снага, својство, особина, капацитет, домет, дејство, страна, надлежност, квалитета, инфраструктура, текстура, отров … |
| 36 | 9 | 0,155 | имати, нематu, представљати, поседовати | właściwości i cechy | вредност, однос, тенденција, карактеристика, средство, садржај, густина, војник, намена |
| 37 | 26 | 0,275 | представљати, имати, стварати, чинити | mieszany: wielkości i kategorie *(niejednorodny)* | величина, скуп, категорија, предмет, спорт, отвор, претња, фактор, грађевина, галерија, срце, средина … |
| 38 | 9 | 0,244 | чинити, представљати, имати, стварати | mieszany: różnice i podziały *(niejednorodny)* | разлика, линија, избор, целина, кухиње, изузетак, продаја, врт, мањина |
| 39 | 10 | 0,392 | основати, формирати, чинити, представљати | grupy społeczne i organizacje | група, држава, веза, традиција, влада, заједница, центар, организација, савет, коњица |
| 40 | 38 | 0,521 | садржати, имати, користити, чинити | substancje i składniki chemiczne | материја, киселина, бакар, литијум, протеина, кисеоник, проценат, маст, састојка, шећер, комбинација, седиште … |
| 41 | 12 | 0,311 | садржати, дати, давати, имати | substancje i składniki chemiczne *(niejednorodny)* | количина, вода, ниво, елемент, ћелија, информација, податак, пигмент, млеко, аањон, фосфор, спречавање |
| 42 | 35 | 0,315 | дати, давати, добити, имати | korzyści i cechy nadawane | предност, боја, резултат, простор, укус, производ, допринос, дефиниција, прилика, квалитет, поље, утисак … |
| 43 | 33 | 0,292 | добити, добијати, дати, давати | nazwy i formy otrzymywane | име, облик, време, значење, карактер, изглед, форма, устав, аутономија, тон, новац, одговор … |
| 44 | 27 | 0,392 | стећи, добити, добијати, захтевати | prawa i status zdobywane | право, статус, контрола, независност, знање, дозвола, образовање, популарност, искуство, пажња, зона, самосталност … |
| 45 | 8 | 0,422 | нематu, имати, изгубити, поседовати | mieszany: znaczenie i kompetencje *(niejednorodny)* | значај, зуб, овлашћење, пречник, битак, муж, електрона, отац |
| 46 | 30 | 0,410 | нематu, имати, представљати, садржати | mieszany: narządy i cechy *(niejednorodny)* | мембрана, око, смисао, жица, захтев, излаз, религија, намера, претак, крила, изотоп, саобраћај … |
| 47 | 12 | 0,294 | чинити, представљати, имати, нематu | części składowe całości | период, тачка, компонент, тим, рачунар, половина, кожа, стуб, остатак, архитектура, ослонац, раздобље |
| 48 | 30 | 0,322 | чинити, имати, покривати, представљати | obszar i ludność | површина, већина, подручје, популација, становништво, трошак, дио, састав, трећина, земљиште, привреда, омотач … |
| 49 | 34 | 0,342 | формирати, чинити, градити, имати | struktury tworzone | структура, основ, мрежа, маса, језеро, органа, стање, слој, јединење, ред, јединица, интеракција … |

*Tabela 16. Zawartość wszystkich 50 neuronów (N – liczba rzeczowników, Spójn. – średnie podobieństwo kosinusowe rzeczowników w klastrze; pełne listy: wyniki/lab04/neurony.csv).*

## 4.7. Analiza klastrów

**Neurony martwe.** 0 z 50 neuronów nie wygrało dla żadnego rzeczownika. Wszystkie neurony się czegoś nauczyły. Wynika to z proporcji danych do rozmiaru sieci: na jeden neuron przypada średnio 20 rzeczowników, a szerokie sąsiedztwo na początku uczenia rozciąga całą siatkę na obszar zajmowany przez dane, zanim neurony się wyspecjalizują. Najmniejsze klastry (3–7 rzeczowników) leżą na granicach dużych skupień i zbierają rzeczowniki o nietypowych profilach – to neurony, które nauczyły się „niewiele”: nie reprezentują żadnego pola znaczeniowego.

**Spójność.** Średnie podobieństwo kosinusowe dwóch rzeczowników z tego samego klastra wynosi 0,34, a dwóch dowolnych rzeczowników – 0,07. Klastry skupiają więc rzeczowniki o wyraźnie podobnych profilach czasowników.

**Pola semantyczne.** Zawartość każdego neuronu oceniliśmy ręcznie (tabela 16). **35 klastrów jest jednorodnych** – ich rzeczowniki należą do wspólnego pola semantycznego; 11 klastrów jest mieszanych (da się wskazać dominujący motyw, ale rzeczowniki pochodzą z różnych pól), a 4 małe neurony (#1, #10, #16, #24) nie mają żadnego wspólnego pola. Klastry jednorodne tworzą **33 różne pola semantyczne** – niektóre pola zajmują dwa sąsiednie neurony:

| Pole semantyczne | Neurony | Przykładowe rzeczowniki |
|---|---|---|
| pomoc, wsparcie, ochrona | #2 | могућност, подршка, заштита, енергија, помоћ, извор |
| etapy dziejów: rozkwit i upadek | #3 | пораз, пад, револуција, година, напредак, процват |
| skutki negatywne: choroby, szkody, straty | #4, #5 | промена, болест, потреба, губитак, потешкоћа, случај, проблем, ефекат, реакција, осећај, оштећење, повећање |
| procesy i zmiany | #6 | употреба, развој, кретање, стварање, смањење, појава |
| czynności i działania | #7 | примена, рад, приступ, корак, коришћење, истраживање |
| działania wykonywane: ataki, reformy, służba | #8 | утицај, функција, процес, инвазија, задатак, напад |
| wojna, polityka, walka (prowadzić) | #9 | порекло, посао, политика, живот, рат, реч |
| teorie i systemy pojęć | #11 | клима, језик, теорија, музика, концепт, календар |
| władza, odpowiedzialność, propozycje | #12 | власт, услов, идеја, одговорност, предлог, вођство |
| decyzje i akty prawne | #13 | одлука, закон, победа, култура, циљ, пласман |
| osiągnięcia: gole, sukcesy | #14 | гол, успех, погодак, успеха, успјех, васкрсење |
| cechy i przejawy zachowania | #15 | степен, ефект, варијација, сличност, симптом, понашање |
| wydarzenia organizowane: gry, wystawy, referenda | #19 | игра, суд, такмичење, покрет, бог, изложба |
| metody, techniki, narzędzia | #20 | метод, техника, термин, мотор, симбол, дрво |
| systemy, programy, modele | #21 | систем, програм, инструмент, стил, верзија, бојати |
| teksty i dzieła | #22 | део, правило, историја, књига, писмо, извештај |
| trofea i zawody sportowe | #23 | титула, медаља, град, награда, првенство, пут |
| wielkości, które rosną i maleją | #25 | способност, брзина, производња, граница, ризик, дужина |
| jednostki miary i liczebność | #26 | становник, тона, сило, деца, долар, резерва |
| porozumienia i związki | #28 | породица, обичај, контакт, унија, споразум, суверенитет |
| państwa i instytucje zakładane | #29 | царство, члан, насеље, црква, колонија, индустрија |
| materiały i substancje wytwarzane | #30 | материјал, ресурс, супстанац, гас, фреквенција, лук |
| miejsca i pozycje zajmowane | #33 | место, земља, позиција, став, глас, важност |
| role i terytoria zdobywane | #34 | улога, територија, утакмица, моћ, положај, меч |
| właściwości i cechy | #35, #36 | снага, својство, особина, капацитет, домет, дејство, вредност, однос, тенденција, карактеристика, средство, садржај |
| grupy społeczne i organizacje | #39 | група, држава, веза, традиција, влада, заједница |
| substancje i składniki chemiczne | #40 | материја, киселина, бакар, литијум, протеина, кисеоник |
| korzyści i cechy nadawane | #42 | предност, боја, резултат, простор, укус, производ |
| nazwy i formy otrzymywane | #43 | име, облик, време, значење, карактер, изглед |
| prawa i status zdobywane | #44 | право, статус, контрола, независност, знање, дозвола |
| części składowe całości | #47 | период, тачка, компонент, тим, рачунар, половина |
| obszar i ludność | #48 | површина, већина, подручје, популација, становништво, трошак |
| struktury tworzone | #49 | структура, основ, мрежа, маса, језеро, органа |

*Tabela 17. Pola semantyczne (33) utworzone przez klastry jednorodne.*

| Klaster mieszany | Neuron | Przykładowe rzeczowniki |
|---|---|---|
| przedmioty noszone: broń, oznaki, rękawice | #0 | назив, опрема, корен, тежина, топ, оружје, ознака, крв, кост, застава |
| przyroda i różne obiekty | #17 | животиња, почетак, реп, аспект, објект, море, долина, пракса, представник, организам |
| działalność i wydarzenia | #18 | догађај, биљак, размена, делатност, жена, дистрибуција, путовање, каријера, убиство, краљ |
| ludzie, instytucje, normy | #27 | човек, син, стандард, институција, уметност, потенцијал, сцена, питање, ограничење, оквир |
| rodzaje i sposoby | #31 | врста, низ, начин, пар, тело, вино, топлота, тип, мноштво, пример |
| dźwięki, obrazy, ślady | #32 | звук, слика, траг, последица, острво, план, сигнал, терен, мишљење, правац |
| wielkości i kategorie | #37 | величина, скуп, категорија, предмет, спорт, отвор, претња, фактор, грађевина, галерија |
| różnice i podziały | #38 | разлика, линија, избор, целина, кухиње, изузетак, продаја, врт, мањина |
| substancje i składniki chemiczne | #41 | количина, вода, ниво, елемент, ћелија, информација, податак, пигмент, млеко, анјон |
| znaczenie i kompetencje | #45 | значај, зуб, овлашћење, пречник, битак, муж, електрона, отац |
| narządy i cechy | #46 | мембрана, око, смисао, жица, захтев, излаз, религија, намера, претак, крила |

*Tabela 18. Klastry niejednorodne (dominujący motyw i przykłady).*

**Ocena klastrów.** Sieć rzeczywiście spontanicznie wytworzyła klastry, w których rzeczowniki należą do wspólnego pola semantycznego. Najbardziej jednorodne są klastry wyznaczone przez czasowniki o wąskim zakresie dopełnień:

• **trofea i zawody sportowe** (освојити – zdobyć): титула, медаља, првенство, турнир, лига, куп, бод, поен;
• **substancje i składniki chemiczne** (садржати – zawierać): киселина, бакар, кисеоник, протеин, шећер, маст, литијум;
• **skutki negatywne** – dwa sąsiednie neurony (изазвати, узроковати – wywołać, spowodować): болест, смрт, бол, повреда, оштећење, депресија, загађење;
• **decyzje i akty prawne** (донети, усвојити – podjąć, uchwalić): одлука, закон, декларација, резолуција, акт;
• **działania wojenne i polityczne** (извршити – dokonać, водити – prowadzić): инвазија, напад, реформа; рат, политика, борба, преговор;
• **państwa i instytucje** (основати – założyć): царство, колонија, република, школа, друштво, болница; obok nich **grupy i organizacje** (формирати – utworzyć): група, влада, заједница, организација;
• **prawa i status** (стећи – zdobyć, uzyskać): право, статус, контрола, независност; **nazwy** (добити – otrzymać): име, облик, значење, изглед.

**Topologia.** Pokrewne pola leżą obok siebie: dwa neurony skutków negatywnych sąsiadują z procesami i zmianami, pola „prawa i status” i „nazwy otrzymywane” są w sąsiednich neuronach dolnego wiersza, a „państwa i instytucje” stykają się z „grupami i organizacjami”.

**Ograniczenia.** 11 klastrów uznaliśmy za niejednorodne. Są to głównie neurony czasowników o bardzo ogólnym znaczeniu (укључивати – obejmować, чинити – stanowić, давати – dawać, немати – nie mieć), które przyjmują dopełnienia z dowolnego pola. Rzeczowniki konkretne (zwierzęta, jedzenie, ubrania) rzadko występują w encyklopedycznym tekście jako dopełnienie i mają tylko kilka fraz VO, dlatego nie utworzyły osobnych klastrów, tylko trafiły do klastrów mieszanych. Sieć grupuje więc rzeczowniki według *zachowania składniowego*: tam, gdzie czasownik jest wybiórczy, daje to jednorodne pole znaczeniowe; tam, gdzie jest ogólny – mieszankę.

# 5. Laboratorium 5 – analiza syntaktyczna: generator zdań SVO

**Zadanie:** opracować generator zdań prostych typu SVO (podmiot – orzeczenie – dopełnienie bliższe). Podmiotem jest fraza rzeczownikowa lub zaimek osobowy, orzeczeniem czasownik nieprzechodni, przechodni lub zwrotny we wszystkich możliwych w danym języku czasach, trybach (oznajmujący, pytający, przeczący, rozkazujący, przypuszczający) i stronach (czynna, bierna), a dopełnieniem fraza rzeczownikowa lub zaimek osobowy. Fraza rzeczownikowa to rzeczownik, opcjonalnie poprzedzony przymiotnikiem i rodzajnikiem lub zaimkiem. Leksykon: co najmniej 100 rzeczowników, 100 czasowników i 100 przymiotników.

**W prostych słowach**

Generator składa zdanie z klocków: losuje czasownik, do niego pasujący podmiot i (jeśli czasownik jest przechodni) dopełnienie, a potem losuje czas, tryb i stronę. Najtrudniejsza jest odmiana: serbski ma 7 przypadków, 3 rodzaje, zgodę przymiotnika i imiesłowu z rzeczownikiem oraz „enklityki” – krótkie słówka (сам, је, га, се, ће…), które muszą stać na drugim miejscu w zdaniu w ściśle określonej kolejności. Generator zna te reguły, więc „Ја сам га видео” (Widziałem go) powstaje poprawnie, a nie jako „Ја видео сам њега”.

## 5.1. Leksykon

Leksykon jest w pliku `leksykon_svo.py`, a generator w `lab05_generator_svo.py`. Wyrazy zapisano łacinką (w niej łatwiej kontrolować odmianę), a zdania są wypisywane cyrylicą i łacinką (transliteracja jest jednoznaczna). Użyto wymowy ekawskiej (standard w Serbii).

| Część leksykonu | Liczba | Szczegóły |
|---|---|---|
| rzeczowniki | 106 | m: 60, ż: 32, n: 14; dla każdego 6 form: mianownik, dopełniacz, biernik × l. poj./mn.; żywotność; klasa znaczeniowa |
| czasowniki | 120 | przechodnie 77, nieprzechodnie 24, zwrotne 19; niedokonane 60, dokonane 60; przechodnie z imiesłowem biernym |
| przymiotniki | 105 | forma określona, z listą klas rzeczowników, do których pasują |
| określniki | 14 | wskazujący: 3, dzierżawczy: 7, nieokreślony: 2, upowszechniający: 1; zwrotny dzierżawczy свој |
| zaimki osobowe | 10 | ја, ти, он, она, оно, ми, ви, они, оне, она (M., B. enklityczny, B. pełny, D.) |

*Tabela 19. Zawartość leksykonu generatora.*

Serbski **nie ma rodzajników**. Ich funkcję pełnią zaimki: *један* (jeden, pewien) działa jak rodzajnik nieokreślony, a *тај* (ten) jak określony. Dlatego jako „element dodatkowy” frazy rzeczownikowej generator używa zaimków wskazujących (овај, тај, онај), dzierżawczych (мој, твој, његов, њен, наш, ваш, њихов, свој), nieokreślonych (један, неки) i upowszechniającego (сваки).

| Rzeczownik | Znaczenie | Rod z. | Kl. | Rzeczownik | Znaczenie | Rod z. | Kl. | Rzeczownik | Znaczenie | Rod z. | Kl. |
|---|---|---|---|---|---|---|---|---|---|---|---|
| човек | człowiek | m* | H | пријатељ | przyjaciel | m* | H | учитељ | nauczyciel | m* | H |
| студент | student | m* | H | лекар | lekarz | m* | H | војник | żołnierz | m* | H |
| краљ | król | m* | H | сусед | sąsiad | m* | H | дечак | chłopiec | m* | H |
| ловац | myśliwy | m* | H | писац | pisarz | m* | H | певач | piosenkarz | m* | H |
| радник | robotnik | m* | H | сељак | chłop, rolnik | m* | H | кувар | kucharz | m* | H |
| возач | kierowca | m* | H | рибар | rybak | m* | H | гост | gość | m* | H |
| лопов | złodziej | m* | H | полицајац | policjant | m* | H | новинар | dziennikarz | m* | H |
| син | syn | m* | H | отац | ojciec | m* | H | жена | kobieta | f* | H |
| девојка | dziewczyna | f* | H | мајка | matka | f* | H | сестра | siostra | f* | H |
| учитељица | nauczycielka | f* | H | пас | pies | m* | A | коњ | koń | m* | A |
| вук | wilk | m* | A | медвед | niedźwiedź | m* | A | орао | orzeł | m* | A |
| лав | lew | m* | A | зец | zając | m* | A | мачка | kot | f* | A |
| крава | krowa | f* | A | птица | ptak | f* | A | риба | ryba | f* | AF |
| хлеб | chleb | m | F | сир | ser | m | F | колач | ciasto | m | F |
| кромпир | ziemniak | m | FP | јабука | jabłko | f | FP | јаје | jajko | n | F |
| месо | mięso | n | F | јело | potrawa | n | F | воће | owoce | n | F |
| поврће | warzywa | n | F | кафа | kawa | f | D | вода | woda | f | D |
| вино | wino | n | D | млеко | mleko | n | D | чај | herbata | m | D |
| пиво | piwo | n | D | нож | nóż | m | O | сто | stół | m | O |
| телефон | telefon | m | O | рачунар | komputer | m | O | кључ | klucz | m | O |
| папир | papier | m | O | камен | kamień | m | O | поклон | prezent | m | O |
| прозор | okno | m | O | торба | torba | f | O | оловка | ołówek | f | O |
| чаша | szklanka | f | O | лопта | piłka | f | O | гитара | gitara | f | OI |
| огледало | lustro | n | O | ствар | rzecz | f | O | кост | kość | f | OK |
| капут | płaszcz | m | C | шешир | kapelusz | m | C | хаљина | sukienka | f | C |
| ципела | but | f | C | аутомобил | samochód | m | V | воз | pociąg | m | V |
| брод | statek | m | V | бицикл | rower | m | V | град | miasto | m | B |
| мост | most | m | B | зид | mur | m | B | дворац | zamek | m | B |
| кућа | dom | f | B | школа | szkoła | f | B | црква | cerkiew | f | B |
| зграда | budynek | f | B | улица | ulica | f | B | село | wieś | n | B |
| позориште | teatr | n | B | језеро | jezioro | n | B | књига | książka | f | T |
| писмо | list | n | T | закон | ustawa | m | T | уговор | umowa | m | T |
| филм | film | m | T | песма | piosenka, wiersz | f | TM | слика | obraz | f | TO |
| карта | bilet, mapa | f | T | вест | wiadomość | f | T | реч | słowo | f | T |
| цвет | kwiat | m | P | новац | pieniądze | m | N | зуб | ząb | m | K |
| срце | serce | n | K | | | | | | | | |

*Tabela 20. Rzeczowniki (* – żywotne; klasy: H ludzie, A zwierzęta, F jedzenie, D napoje, O przedmioty, C ubrania, V pojazdy, B budynki/miejsca, T teksty/dzieła, M utwory muzyczne, I instrumenty, P rośliny, N pieniądze, K części ciała).*

| Czasownik | Znaczenie | Typ | Asp. | Czasownik | Znaczenie | Typ | Asp. |
|---|---|---|---|---|---|---|---|
| читати | czytać | tr | impf | оставити | zostawić | tr | pf |
| прочитати | przeczytać | tr | pf | чувати | pilnować, przechowywać | tr | impf |
| писати | pisać | tr | impf | посадити | posadzić | tr | pf |
| написати | napisać | tr | pf | брати | zrywać, zbierać | tr | impf |
| видети | widzieć | tr | impf | платити | zapłacić za | tr | pf |
| гледати | oglądać, patrzeć na | tr | impf | зарадити | zarobić | tr | pf |
| волети | kochać, lubić | tr | impf | бројати | liczyć | tr | impf |
| мрзети | nienawidzić | tr | impf | показати | pokazać | tr | pf |
| јести | jeść | tr | impf | потписати | podpisać | tr | pf |
| појести | zjeść | tr | pf | снимити | nagrać, sfilmować | tr | pf |
| пити | pić | tr | impf | знати | znać | tr | impf |
| попити | wypić | tr | pf | заборавити | zapomnieć | tr | pf |
| пробати | spróbować | tr | pf | љубити | całować | tr | impf |
| купити | kupić | tr | pf | лечити | leczyć | tr | impf |
| куповати | kupować | tr | impf | позајмити | pożyczyć | tr | pf |
| продати | sprzedać | tr | pf | очистити | wyczyścić | tr | pf |
| носити | nosić | tr | impf | запалити | zapalić, podpalić | tr | pf |
| донети | przynieść | tr | pf | спавати | spać | intr | impf |
| однети | odnieść, zabrać | tr | pf | трчати | biec, biegać | intr | impf |
| изгубити | zgubić | tr | pf | ходати | chodzić | intr | impf |
| наћи | znaleźć | tr | pf | седети | siedzieć | intr | impf |
| тражити | szukać | tr | impf | стајати | stać | intr | impf |
| отворити | otworzyć | tr | pf | лежати | leżeć | intr | impf |
| затворити | zamknąć | tr | pf | плакати | płakać | intr | impf |
| градити | budować | tr | impf | пливати | pływać | intr | impf |
| саградити | zbudować | tr | pf | летети | latać, lecieć | intr | impf |
| уништити | zniszczyć | tr | pf | радити | pracować | intr | impf |
| прати | myć, prać | tr | impf | живети | żyć, mieszkać | intr | impf |
| опрати | umyć, wyprać | tr | pf | путовати | podróżować | intr | impf |
| кувати | gotować | tr | impf | лајати | szczekać | intr | impf |
| скувати | ugotować | tr | pf | ћутати | milczeć | intr | impf |
| пећи | piec | tr | impf | каснити | spóźniać się | intr | impf |
| сећи | kroić, ciąć | tr | impf | умрети | umrzeć | intr | pf |
| хранити | karmić | tr | impf | доћи | przyjść, przyjechać | intr | pf |
| ловити | łowić, polować na | tr | impf | отићи | odejść, odjechać | intr | pf |
| ухватити | złapać | tr | pf | ићи | iść, jechać | intr | impf |
| убити | zabić | tr | pf | пасти | upaść | intr | pf |
| возити | prowadzić (pojazd) | tr | impf | скочити | skoczyć | intr | pf |
| поправити | naprawić | tr | pf | побећи | uciec | intr | pf |
| сломити | złamać | tr | pf | заспати | zasnąć | intr | pf |
| бацити | rzucić, wyrzucić | tr | pf | цветати | kwitnąć | intr | impf |
| добити | dostać | tr | pf | смејати се | śmiać się | refl | impf |
| дати | dać | tr | pf | насмејати се | zaśmiać się | refl | pf |
| послати | wysłać | tr | pf | радовати се | cieszyć się | refl | impf |
| примити | otrzymać, przyjąć | tr | pf | бојати се | bać się | refl | impf |
| слушати | słuchać | tr | impf | умивати се | myć się | refl | impf |
| учити | uczyć się (czegoś) | tr | impf | умити се | umyć się | refl | pf |
| научити | nauczyć się | tr | pf | облачити се | ubierać się | refl | impf |
| цртати | rysować | tr | impf | шетати се | spacerować | refl | impf |
| певати | śpiewać | tr | impf | играти се | bawić się | refl | impf |
| свирати | grać (na instrumencie) | tr | impf | вратити се | wrócić | refl | pf |
| позвати | zaprosić, zawołać | tr | pf | пробудити се | obudzić się | refl | pf |
| поздравити | pozdrowić | tr | pf | купати се | kąpać się | refl | impf |
| посетити | odwiedzić | tr | pf | одмарати се | odpoczywać | refl | impf |
| чекати | czekać na | tr | impf | одморити се | odpocząć | refl | pf |
| бранити | bronić | tr | impf | надати се | mieć nadzieję | refl | impf |
| напасти | zaatakować | tr | pf | свађати се | kłócić się | refl | impf |
| победити | pokonać | tr | pf | попети се | wspiąć się | refl | pf |
| обући | włożyć (ubranie) | tr | pf | заљубити се | zakochać się | refl | pf |
| скинути | zdjąć | tr | pf | осмехнути се | uśmiechnąć się | refl | pf |

*Tabela 21. Czasowniki (tr – przechodni, intr – nieprzechodni, refl – zwrotny; impf – niedokonany, pf – dokonany).*

| Przymiotnik | Znaczenie | Przymiotnik | Znaczenie | Przymiotnik | Znaczenie | Przymiotnik | Znaczenie |
|---|---|---|---|---|---|---|---|
| нови | nowy | кисели | kwaśny | чисти | czysty | страни | obcy |
| стари | stary | слани | słony | прљави | brudny | дрвени | drewniany |
| млади | młody | горки | gorzki | суви | suchy | камени | kamienny |
| велики | duży | укусни | smaczny | мокри | mokry | златни | złoty |
| мали | mały | свежи | świeży | тешки | ciężki | сребрни | srebrny |
| лепи | ładny | скупи | drogi | лаки | lekki | стаклени | szklany |
| ружни | brzydki | јефтини | tani | дуги | długi | вунени | wełniany |
| добри | dobry | богати | bogaty | кратки | krótki | кожни | skórzany |
| лоши | zły, kiepski | сиромашни | biedny | широки | szeroki | гвоздени | żelazny |
| брзи | szybki | срећни | szczęśliwy | уски | wąski | модерни | nowoczesny |
| спори | wolny | тужни | smutny | дубоки | głęboki | древни | starożytny |
| високи | wysoki | паметни | mądry | плитки | płytki | савремени | współczesny |
| ниски | niski | глупи | głupi | округли | okrągły | главни | główny |
| дебели | gruby | храбри | odważny | оштри | ostry | огромни | ogromny |
| танки | cienki | уморни | zmęczony | меки | miękki | мрачни | ciemny |
| црвени | czerwony | гладни | głodny | тврди | twardy | светли | jasny |
| плави | niebieski | жедни | spragniony | празни | pusty | сјајни | lśniący, świetny |
| зелени | zielony | здрави | zdrowy | пуни | pełny | чудни | dziwny |
| жути | żółty | болесни | chory | познати | znany | обични | zwykły |
| црни | czarny | јаки | silny | непознати | nieznany | посебни | szczególny |
| бели | biały | слаби | słaby | важни | ważny | озбиљни | poważny |
| сиви | szary | љубазни | uprzejmy | занимљиви | ciekawy | вредни | pracowity, cenny |
| смеђи | brązowy | љути | zły, gniewny | досадни | nudny | локални | lokalny |
| топли | ciepły | весели | wesoły | опасни | niebezpieczny | ретки | rzadki |
| хладни | zimny | мирни | spokojny | сигурни | bezpieczny | | |
| врући | gorący | гласни | głośny | дивљи | dziki | | |
| слатки | słodki | тихи | cichy | домаћи | domowy | | |

*Tabela 22. Przymiotniki (forma określona, rodzaj męski).*

## 5.2. Fraza rzeczownikowa i jej odmiana

Fraza rzeczownikowa ma postać [określnik] [przymiotnik] rzeczownik. Wszystkie trzy elementy zgadzają się w rodzaju, liczbie i przypadku. Podmiot stoi w mianowniku, dopełnienie bliższe w bierniku, a wykonawca czynności w stronie biernej w dopełniaczu (*од стране* + D.). Rzeczowniki męskie **żywotne** mają w bierniku l. poj. formę dopełniacza (видим пса – widzę psa), a nieżywotne – formę mianownika (видим град – widzę miasto). Gdy posiadaczem dopełnienia jest podmiot, zaimek dzierżawczy zmienia się na zwrotny *свој* (Ја читам *своју* књигу – Czytam swoją książkę).

| Fraza | Mianownik (podmiot) | Biernik (dopełnienie) | Dopełniacz (wykonawca) |
|---|---|---|---|
| naš + veliki + pas (l. poj.) | наш велики пас | нашег великог пса | нашег великог пса |
| ovaj + stari + grad (l. poj.) | овај стари град | овај стари град | овог старог града |
| moj + novi + knjiga (l. poj.) | моја нова књига | моју нову књигу | моје нове књиге |
| taj + dugi + pismo (l. mn.) | та дуга писма | та дуга писма | тих дугих писама |
| neki + mladi + devojka (l. mn.) | неке младе девојке | неке младе девојке | неких младих девојака |

*Tabela 23. Przykłady odmiany frazy rzeczownikowej.*

## 5.3. Orzeczenie: czasy, tryby i strony

Serbski ma siedem czasów trybu oznajmującego, dwa czasy trybu przypuszczającego (potencijal) i tryb rozkazujący. Każdą formę można postawić w zdaniu oznajmującym lub pytającym (*да ли* …?) oraz twierdzącym lub przeczącym. Pięć „trybów” z polecenia realizujemy więc jako trzy tryby gramatyczne × typ zdania × polaryzację, co daje także kombinacje (np. pytanie przeczące w potencjale).

| Forma | Znaczenie | Budowa | Przykład |
|---|---|---|---|
| prezent | czas teraźniejszy | forma osobowa | Ја читам књигу. |
| perfekat | przeszły złożony | сам/си/је… + imiesłów na -l | Ја сам читао књигу. |
| aorist | przeszły dokonany (literacki) | forma syntetyczna | Ја прочитах књигу. |
| imperfekat | przeszły niedokonany (literacki), tylko czas. niedokonane | forma syntetyczna | Ја читах књигу. |
| pluskvamperfekat | zaprzeszły | сам био + imiesłów na -l | Ја сам био читао књигу. |
| futur I | przyszły | ћу/ћеш… + bezokolicznik | Ја ћу читати књигу. |
| futur II | przyszły uprzedni (tylko w zdaniach warunkowych/czasowych) | будем + imiesłów | Ако ја будем читао књигу… |
| potencijal I | tryb przypuszczający | бих/би… + imiesłów | Ја бих читао књигу. |
| potencijal II | tryb przypuszczający przeszły | бих био + imiesłów | Ја бих био читао књигу. |
| imperativ | tryb rozkazujący (ti, mi, vi) | forma syntetyczna; przeczenie: не / немој + bezok. | Ти читај књигу! Немој прочитати! |
| imperativ z нека | rozkaz dla 1. os. lp. i 3. os. | нека + prezent | Нека он чита књигу! |
| strona bierna | wszystkie czasy oprócz zaprzeszłego | бити + imiesłów bierny (+ од стране D.) | Књига је прочитана од стране мог брата. |

*Tabela 24. Formy orzeczenia obsługiwane przez generator.*

Formy regularne generator tworzy sam z bezokolicznika i 1. os. lp. czasu teraźniejszego (np. aoryst: читати → читах, чита, читасмо, читасте, читаше; imperatyw: читају → читај, пишу → пиши). Formy nieregularne (np. јести → једох, јео; доћи → дођох, дошао; пећи → пеци) są zapisane w leksykonie. Imiesłowy zgadzają się z podmiotem w rodzaju i liczbie: читао (on), читала (ona), читало (ono), читали (oni), читале (one), читала (ona – l. mn. nijaka). Kombinacje niemożliwe w serbskim są odrzucane: imperfekt czasowników dokonanych, strona bierna czasowników nieprzechodnich i zwrotnych, pytanie w trybie rozkazującym, futur II w zdaniu pytającym.

## 5.4. Szyk zdania i enklityki

Podstawowy szyk to SVO, ale serbskie enklityki (słowa bez akcentu) muszą stać na **drugim miejscu** w zdaniu – po pierwszej frazie (podmiocie albo *да ли*, *нека*, *ако*). Generator ustawia je w kolejności: *li* – czasownik posiłkowy (сам, си, смо, сте, су, бих, ћу…) – zaimek w bierniku (ме, те, га, је, нас, вас, их) – *се* – *је*. Dodatkowo: posiłkowe је znika po се (Он се смејао), a zaimek je przed posiłkowym је zmienia się w ју (Он ју је видео). Dopełnienie-zaimek ma formę enklityczną, więc w tym przypadku szyk staje się SOV – tak jak wymaga gramatyka.

| Zdanie | Tłumaczenie |
|---|---|
| Ја сам га видео. | Widziałem go. |
| Он ју је видео. | On ją widział. |
| Да ли си ти видела тог пса? | Czy (ty) widziałaś tego psa? |
| Ми се нисмо смејали. | Nie śmialiśmy się. |
| Нека га он чита! | Niech on go czyta! |
| Ви бисте се били смејали. | Bylibyście się śmiali. |

*Tabela 25. Przykłady szyku enklityk.*

## 5.5. Ograniczenia znaczeniowe

Zdania mają być nie tylko poprawne gramatycznie, ale też sensowne. Każdy rzeczownik ma klasę znaczeniową, a każdy czasownik listę klas dozwolonych dla podmiotu i dopełnienia (np. јести: podmiot H/A – człowiek lub zwierzę, dopełnienie F – jedzenie; возити: dopełnienie V – pojazd). Podobnie przymiotniki mają listę klas, do których pasują (зелени цвет tak, зелена вест nie). Zaimki 1. i 2. osoby mogą być tylko ludźmi.

## 5.6. Wyniki

| Strona | Tryb | Czas | Typ | Polaryz. | Zdanie |
|---|---|---|---|---|---|
| czynna | oznajmujący | prezent | oznajmujące | twierdzące | Ја прочитам своју нову књигу. |
| czynna | oznajmujący | prezent | oznajmujące | przeczące | Ја не прочитам своју нову књигу. |
| czynna | oznajmujący | prezent | pytające | twierdzące | Да ли ја прочитам своју нову књигу? |
| czynna | oznajmujący | prezent | pytające | przeczące | Да ли ја не прочитам своју нову књигу? |
| czynna | oznajmujący | perfekat | oznajmujące | twierdzące | Ја сам прочитао своју нову књигу. |
| czynna | oznajmujący | perfekat | oznajmujące | przeczące | Ја нисам прочитао своју нову књигу. |
| czynna | oznajmujący | perfekat | pytające | twierdzące | Да ли сам ја прочитао своју нову књигу? |
| czynna | oznajmujący | perfekat | pytające | przeczące | Да ли ја нисам прочитао своју нову књигу? |
| czynna | oznajmujący | aorist | oznajmujące | twierdzące | Ја прочитах своју нову књигу. |
| czynna | oznajmujący | aorist | oznajmujące | przeczące | Ја не прочитах своју нову књигу. |
| czynna | oznajmujący | aorist | pytające | twierdzące | Да ли ја прочитах своју нову књигу? |
| czynna | oznajmujący | aorist | pytające | przeczące | Да ли ја не прочитах своју нову књигу? |
| czynna | oznajmujący | pluskvamperfekat | oznajmujące | twierdzące | Ја сам био прочитао своју нову књигу. |
| czynna | oznajmujący | pluskvamperfekat | oznajmujące | przeczące | Ја нисам био прочитао своју нову књигу. |
| czynna | oznajmujący | pluskvamperfekat | pytające | twierdzące | Да ли сам ја био прочитао своју нову књигу? |
| czynna | oznajmujący | pluskvamperfekat | pytające | przeczące | Да ли ја нисам био прочитао своју нову књигу? |
| czynna | oznajmujący | futur I | oznajmujące | twierdzące | Ја ћу прочитати своју нову књигу. |
| czynna | oznajmujący | futur I | oznajmujące | przeczące | Ја нећу прочитати своју нову књигу. |
| czynna | oznajmujący | futur I | pytające | twierdzące | Да ли ћу ја прочитати своју нову књигу? |
| czynna | oznajmujący | futur I | pytające | przeczące | Да ли ја нећу прочитати своју нову књигу? |
| czynna | oznajmujący | futur II | oznajmujące | twierdzące | Ако ја будем прочитао своју нову књигу… |
| czynna | oznajmujący | futur II | oznajmujące | przeczące | Ако ја не будем прочитао своју нову књигу… |
| czynna | rozkazujący | imperativ | oznajmujące | twierdzące | Нека ја прочитам своју нову књигу! |
| czynna | rozkazujący | imperativ | oznajmujące | przeczące | Нека ја не прочитам своју нову књигу! |
| czynna | przypuszczający | potencijal I | oznajmujące | twierdzące | Ја бих прочитао своју нову књигу. |
| czynna | przypuszczający | potencijal I | oznajmujące | przeczące | Ја не бих прочитао своју нову књигу. |
| czynna | przypuszczający | potencijal I | pytające | twierdzące | Да ли бих ја прочитао своју нову књигу? |
| czynna | przypuszczający | potencijal I | pytające | przeczące | Да ли ја не бих прочитао своју нову књигу? |
| czynna | przypuszczający | potencijal II | oznajmujące | twierdzące | Ја бих био прочитао своју нову књигу. |
| czynna | przypuszczający | potencijal II | oznajmujące | przeczące | Ја не бих био прочитао своју нову књигу. |
| czynna | przypuszczający | potencijal II | pytające | twierdzące | Да ли бих ја био прочитао своју нову књигу? |
| czynna | przypuszczający | potencijal II | pytające | przeczące | Да ли ја не бих био прочитао своју нову књигу? |
| bierna | oznajmujący | prezent | oznajmujące | twierdzące | Моја нова књига је прочитана. |
| bierna | oznajmujący | prezent | oznajmujące | przeczące | Моја нова књига није прочитана. |
| bierna | oznajmujący | prezent | pytające | twierdzące | Да ли је моја нова књига прочитана? |
| bierna | oznajmujący | prezent | pytające | przeczące | Да ли моја нова књига није прочитана? |
| bierna | oznajmujący | perfekat | oznajmujące | twierdzące | Моја нова књига је била прочитана. |
| bierna | oznajmujący | perfekat | oznajmujące | przeczące | Моја нова књига није била прочитана. |
| bierna | oznajmujący | perfekat | pytające | twierdzące | Да ли је моја нова књига била прочитана? |
| bierna | oznajmujący | perfekat | pytające | przeczące | Да ли моја нова књига није била прочитана? |
| bierna | oznajmujący | aorist | oznajmujące | twierdzące | Моја нова књига би прочитана. |
| bierna | oznajmujący | aorist | oznajmujące | przeczące | Моја нова књига не би прочитана. |
| bierna | oznajmujący | aorist | pytające | twierdzące | Да ли моја нова књига би прочитана? |
| bierna | oznajmujący | aorist | pytające | przeczące | Да ли моја нова књига не би прочитана? |
| bierna | oznajmujący | imperfekat | oznajmujące | twierdzące | Моја нова књига беше прочитана. |
| bierna | oznajmujący | imperfekat | oznajmujące | przeczące | Моја нова књига не беше прочитана. |
| bierna | oznajmujący | imperfekat | pytające | twierdzące | Да ли моја нова књига беше прочитана? |
| bierna | oznajmujący | imperfekat | pytające | przeczące | Да ли моја нова књига не беше прочитана? |
| bierna | oznajmujący | futur I | oznajmujące | twierdzące | Моја нова књига ће бити прочитана. |
| bierna | oznajmujący | futur I | oznajmujące | przeczące | Моја нова књига неће бити прочитана. |
| bierna | oznajmujący | futur I | pytające | twierdzące | Да ли ће моја нова књига бити прочитана? |
| bierna | oznajmujący | futur I | pytające | przeczące | Да ли моја нова књига неће бити прочитана? |
| bierna | oznajmujący | futur II | oznajmujące | twierdzące | Ако моја нова књига буде прочитана… |
| bierna | oznajmujący | futur II | oznajmujące | przeczące | Ако моја нова књига не буде прочитана… |
| bierna | rozkazujący | imperativ | oznajmujące | twierdzące | Нека моја нова књига буде прочитана! |
| bierna | rozkazujący | imperativ | oznajmujące | przeczące | Нека моја нова књига не буде прочитана! |
| bierna | przypuszczający | potencijal I | oznajmujące | twierdzące | Моја нова књига би била прочитана. |
| bierna | przypuszczający | potencijal I | oznajmujące | przeczące | Моја нова књига не би била прочитана. |
| bierna | przypuszczający | potencijal I | pytające | twierdzące | Да ли би моја нова књига била прочитана? |
| bierna | przypuszczający | potencijal I | pytające | przeczące | Да ли моја нова књига не би била прочитана? |

*Tabela 26. Wszystkie 60 formy dla jednej trójki: ја + прочитати + (мој + нови + књига) (strona bierna: „Moja nowa książka została przeczytana”).*

| Lp | Zdanie | Cechy |
|---|---|---|
| 1 | То позориште је било остављено од стране вашег медведа. | bierna, oznajmujący, perfekat, oznajmujące, twierdzące |
| 2 | Нека обични студент уништи његово тешко огледало! | czynna, rozkazujący, imperativ, oznajmujące, twierdzące |
| 3 | Да ли би ваша учитељица бацила ствар? | czynna, przypuszczający, potencijal I, pytające, twierdzące |
| 4 | Краљеви нису каснили. | czynna, oznajmujący, perfekat, oznajmujące, przeczące |
| 5 | Њен лепи рибар не нападне једног госта. | czynna, oznajmujący, prezent, oznajmujące, przeczące |
| 6 | Да ли је један мали цвет био показан? | bierna, oznajmujący, perfekat, pytające, twierdzące |
| 7 | Ако они буду продати… | bierna, oznajmujący, futur II, oznajmujące, twierdzące |
| 8 | Мокра мајка их позајми. | czynna, oznajmujący, prezent, oznajmujące, twierdzące |
| 9 | Да ли је шешир био бачен од стране моје веселе жене? | bierna, oznajmujący, perfekat, pytające, twierdzące |
| 10 | Он не би био прао један јефтини нож. | czynna, przypuszczający, potencijal II, oznajmujące, przeczące |
| 11 | Сваки уморни гост није радио. | czynna, oznajmujący, perfekat, oznajmujące, przeczące |
| 12 | Да ли оне учитељице прочиташе његов филм? | czynna, oznajmujący, aorist, pytające, twierdzące |
| 13 | Ја нисам био љубио њиховог ниског радника. | czynna, oznajmujący, pluskvamperfekat, oznajmujące, przeczące |
| 14 | Њен тихи новинар се није умио. | czynna, oznajmujący, perfekat, oznajmujące, przeczące |
| 15 | Нека ваша здрава јаја буду кувана! | bierna, rozkazujący, imperativ, oznajmujące, twierdzące |
| 16 | Да ли ће наш опасни војник уништити торбу? | czynna, oznajmujący, futur I, pytające, twierdzące |
| 17 | Његови краљеви би били чували песме. | czynna, przypuszczający, potencijal II, oznajmujące, twierdzące |
| 18 | Свако јефтино поврће је било скувано. | bierna, oznajmujący, perfekat, oznajmujące, twierdzące |
| 19 | Да ли је оно ухватило оног младог радника? | czynna, oznajmujący, perfekat, pytające, twierdzące |
| 20 | Они не стоје. | czynna, oznajmujący, prezent, oznajmujące, przeczące |
| 21 | Један ловац ће учити оне вести. | czynna, oznajmujący, futur I, oznajmujące, twierdzące |
| 22 | Ја не знах танке војнике. | czynna, oznajmujący, imperfekat, oznajmujące, przeczące |
| 23 | Ми покажимо чудног суседа! | czynna, rozkazujący, imperativ, oznajmujące, twierdzące |
| 24 | Да ли би они храбри дечаци били пекли твој зелени колач? | czynna, przypuszczający, potencijal II, pytające, twierdzące |
| 25 | Ти ме победи! | czynna, rozkazujący, imperativ, oznajmujące, twierdzące |
| 26 | Пријатељ би био зарадио новац. | czynna, przypuszczający, potencijal II, oznajmujące, twierdzące |
| 27 | Да ли ће нека птица скочити? | czynna, oznajmujący, futur I, pytające, twierdzące |
| 28 | Да ли се ја нећу играти? | czynna, oznajmujący, futur I, pytające, przeczące |
| 29 | Љути орао није био ловљен. | bierna, oznajmujący, perfekat, oznajmujące, przeczące |
| 30 | Сваки велики сељак научи обични закон. | czynna, oznajmujący, aorist, oznajmujące, twierdzące |
| 31 | Да ли се оне не би биле свађале? | czynna, przypuszczający, potencijal II, pytające, przeczące |
| 32 | Нека је она не продају! | czynna, rozkazujący, imperativ, oznajmujące, przeczące |
| 33 | Да ли сваки важни лекар сними жедног коња? | czynna, oznajmujący, prezent, pytające, twierdzące |
| 34 | Гласни кувар се био одморио. | czynna, oznajmujący, pluskvamperfekat, oznajmujące, twierdzące |
| 35 | Ти обуче ципелу. | czynna, oznajmujący, aorist, oznajmujące, twierdzące |
| 36 | Оне пошаљу твој папир. | czynna, oznajmujący, prezent, oznajmujące, twierdzące |
| 37 | Њен велики пас паде. | czynna, oznajmujący, aorist, oznajmujące, twierdzące |
| 38 | Ти ниси видела велики зуб. | czynna, oznajmujący, perfekat, oznajmujące, przeczące |
| 39 | Да ли она нису умрла? | czynna, oznajmujący, perfekat, pytające, przeczące |
| 40 | Њен здрави пас би га слушао. | czynna, przypuszczający, potencijal I, oznajmujące, twierdzące |

*Tabela 27. Pierwsze 40 z 200 losowych zdań (pełna lista: wyniki/lab05/losowe_zdania.csv).*

Pełne wyniki są w folderze `wyniki/lab05/`: raport.txt (leksykon, pełne odmiany czterech trójek SVO – z czasownikiem przechodnim dokonanym i niedokonanym, nieprzechodnim i zwrotnym – oraz 200 losowych zdań), tabele CSV leksykonu i zdań. Generator można też uruchomić interaktywnie: `python lab05_generator_svo.py -n 20 --lacinka`. Poprawność sprawdza 16 zdań wzorcowych zweryfikowanych ręcznie (rozdział 6).

# 6. Sprawdzenie poprawności wyników

Skrypt `sprawdz_wyniki.py` nie korzysta z kodu laboratoriów: każdą wartość liczy od nowa, najprostszą możliwą metodą, i porównuje ją z plikami wynikowymi. Poniżej wynik jego działania.

| Lab | Co sprawdzamy | Wynik |
|---|---|---|
| 1 | w korpusie są tylko litery serbskiego alfabetu i spacje | **OK** |
| 1 | brak cyfr (także np. ², ½) | **OK** |
| 1 | brak interpunkcji i symboli | **OK** |
| 1 | brak liter łacińskich i greckich | **OK** |
| 1 | wszystkie litery są małe | **OK** |
| 1 | brak podwójnych spacji, nowych linii i spacji na brzegach | **OK** |
| 1 | występują wszystkie 30 liter alfabetu (30/30) | **OK** |
| 1 | tekst surowy zawierał znaki, które usunięto | **OK** |
| 2 | [same litery] liczności liter zgodne z korpusem | **OK** |
| 2 | [same litery] udziały procentowe sumują się do 100% (100.0001%) | **OK** |
| 2 | [same litery] kod Huffmana jest prefiksowy (żaden kod nie jest początkiem innego) | **OK** |
| 2 | [same litery] nierówność Krafta: suma 2^(-długość) = 1 | **OK** |
| 2 | [same litery] średnia długość L jest minimalna (= niezależny Huffman) (L = 4.3368) | **OK** |
| 2 | [same litery] H ≤ L < H + 1 (H = 4.3024, L = 4.3368) | **OK** |
| 2 | [litery + spacja] liczności liter zgodne z korpusem | **OK** |
| 2 | [litery + spacja] udziały procentowe sumują się do 100% (99.9999%) | **OK** |
| 2 | [litery + spacja] kod Huffmana jest prefiksowy (żaden kod nie jest początkiem innego) | **OK** |
| 2 | [litery + spacja] nierówność Krafta: suma 2^(-długość) = 1 | **OK** |
| 2 | [litery + spacja] średnia długość L jest minimalna (= niezależny Huffman) (L = 4.2889) | **OK** |
| 2 | [litery + spacja] H ≤ L < H + 1 (H = 4.2588, L = 4.2889) | **OK** |
| 3 | lista 90% ma minimalną długość (bez ostatniego wyrazu < 90%) (11148 wyrazów) | **OK** |
| 3 | liczności wyrazów na liście 90% zgodne z korpusem | **OK** |
| 3 | tabela Zipfa obejmuje wszystkie wyrazy, r·f policzone poprawnie | **OK** |
| 3 | wykładnik Zipfa w raporcie zgodny z obliczonym (s = 0.9584) | **OK** |
| 3 | rdzeń: 100 różnych wyrazów | **OK** |
| 3 | rdzeń: liczby sąsiadów, krawędzi wychodzących i wchodzących poprawne | **OK** |
| 3 | rdzeń to faktycznie 100 wyrazów o największej liczbie sąsiadów (próg: 129 sąsiadów) | **OK** |
| 4 | wybrano 100 różnych czasowników przechodnich i co najmniej 1000 różnych rzeczowników (100 czasowników, 1000 rzeczowników) | **OK** |
| 4 | każdy czasownik ma dopełnienie w ≥ 20% wystąpień (jest przechodni) | **OK** |
| 4 | zbiór treningowy: wektory po 100 składowych, kolumny = wybrane czasowniki | **OK** |
| 4 | suma wektora = liczba fraz VO rzeczownika | **OK** |
| 4 | wszystkie składowe wektorów = liczba fraz VO policzona niezależnie z korpusu (100000 składowych) | **OK** |
| 4 | wybrane rzeczowniki to te najczęściej będące dopełnieniem tych czasowników (próg: 4 fraz VO) | **OK** |
| 4 | sieć Kohonena ma 50 neuronów, każdy rzeczownik trafił do dokładnie jednego | **OK** |
| 4 | przypisanie do neuronów = najbliższy neuron (BMU) policzony od nowa z zapisanych wag | **OK** |
| 4 | lista neuronów martwych (bez żadnego rzeczownika) zgodna z podsumowaniem (martwe: 0) | **OK** |
| 5 | leksykon: ≥ 100 rzeczowników, ≥ 100 czasowników, ≥ 100 przymiotników (106 / 120 / 105) | **OK** |
| 5 | czasowniki przechodnie, nieprzechodnie i zwrotne; przechodnie mają imiesłów bierny (77 / 24 / 19) | **OK** |
| 5 | zdania wzorcowe (sprawdzone ręcznie) generowane dokładnie (16/16) | **OK** |
| 5 | niemożliwe kombinacje są odrzucane (imperfekt dokonanych, bierna nieprzechodnich, pytający rozkazujący) | **OK** |
| 5 | 2000 losowych zdań: tylko cyrylica serbska, wielka litera na początku, znak końca zdania | **OK** |

*Tabela 28. Wyniki testów: zaliczone 41 z 41.*

# 7. Podsumowanie

## Realizacja wymagań

| Wymaganie | Jak zrealizowano | Wynik | Rozdz. |
|---|---|---|---|
| **1. Analiza statystyczna** | | | |
| Korpus min. 100 000 wyrazów | Wikipedia, zostawienie tylko 30 liter cyrylicy | 149 373 wyrazów | 1 |
| Prawo Zipfa | regresja w skali log-log | s = 0,958 | 3.2 |
| Wyrazy potrzebne do rozumienia 90% tekstu | sortowanie i sumowanie udziałów | 11 148 wyrazów (lista CSV) | 3.1 |
| Rdzeń języka: 100 wyrazów o najwięcej sąsiadach | graf sąsiedztwa, ranking stopni węzłów | 100 wyrazów, od и do време | 3.3 |
| (dodatkowo) entropia i kod Huffmana | $H = -\Sigma\ p\ \log_2 p$, algorytm Huffmana | H = 4,302, L = 4,337 bit/znak | 2 |
| **2. Analiza syntaktyczna** | | | |
| Generator zdań SVO; podmiot i dopełnienie: fraza rzeczownikowa lub zaimek | lab05_generator_svo.py, odmiana przez przypadki, enklityki | losowe zdania + pełne odmiany | 5 |
| Czasowniki nieprzechodnie, przechodnie, zwrotne | typ czasownika w leksykonie | 77 / 24 / 19 | 5.1 |
| Wszystkie czasy, tryby (oznajmujący, pytający, przeczący, rozkazujący, przypuszczający), strony | 7 czasów + 2 potencjały + imperatyw; pytanie, przeczenie; strona czynna i bierna | do 60 form na trójkę SVO | 5.3 |
| Min. 100 rzeczowników, 100 czasowników, 100 przymiotników | leksykon_svo.py | 106 / 120 / 105 | 5.1 |
| Fraza rzecz.: [rodzajnik/zaimek] [przymiotnik] rzeczownik | zaimki wskazujące, dzierżawcze (z svoj), nieokreślone (jedan ≈ rodzajnik) | 14 określników | 5.2 |
| **3. Analiza semantyczna** | | | |
| Min. 1000 rzeczowników, 100 czasowników przechodnich | analiza składniowa (stanza), korpus dodatkowy | 1000 rzeczowników, 100 czasowników | 4.1–4.3 |
| Wektory 100 składowych = liczby fraz VO | relacja obj z parsera | macierz 1000 × 100 | 4.4 |
| Sieć Kohonena z 50 neuronami | własna implementacja SOM 5 × 10 | błąd topogr. 19,2% | 4.5 |
| Analiza klastrów: pola semantyczne, ich liczba, neurony martwe | ręczna analiza zawartości neuronów, spójność klastrów | pola semantyczne: 33, neurony martwe: 0 | 4.6–4.7 |
| Sprawozdanie PDF, kod w repozytorium | generuj_sprawozdanie.py, git | ten dokument + README | – |

*Tabela 29. Lista wymagań i miejsce ich realizacji.*

## Najważniejsze wnioski

- **Statystyka:** rozkład liter jest nierównomierny, dlatego kod Huffmana (4,34 bit/znak) jest tylko o 0,034 bitu dłuższy od entropii (4,30 bit/znak). Częstości wyrazów spełniają prawo Zipfa (s = 0,96). Do zrozumienia 90% tekstu potrzeba aż 11 148 wyrazów, bo serbski ma bogatą odmianę. Rdzeń języka tworzą słowa funkcyjne (spójniki, przyimki, czasownik бити).
- **Semantyka:** sieć Kohonena z 50 neuronami, ucząc się bez nauczyciela na wektorach fraz VO 1000 rzeczowników, wytworzyła 35 jednorodnych klastrów tworzących 33 pola semantyczne (m.in. sport, substancje chemiczne, choroby i szkody, akty prawne, wojna, instytucje, prawa i status). 11 klastrów jest mieszanych (czasowniki ogólne), a żaden neuron nie jest martwy. Kluczowe okazało się ważenie IDF, które osłabia czasowniki łączące się ze wszystkim (имати).
- **Składnia:** generator tworzy poprawne zdania we wszystkich 7 czasach, 3 trybach, w zdaniach pytających i przeczących oraz w stronie czynnej i biernej. Najważniejsze dla poprawności okazały się: zgoda imiesłowów z podmiotem, biernik rzeczowników żywotnych i reguły szyku enklityk.

## Uruchomienie programu

`pip install -r requirements.txt`, a następnie `python uruchom_wszystko.py` (lub kolejno lab01.py → lab02… → lab03… → lab04_pobieranie.py → lab04_parsowanie.py → lab04_kohonen.py → lab05_generator_svo.py → sprawdz_wyniki.py → generuj_sprawozdanie.py). Pobrane korpusy i wyniki analizy składniowej są w repozytorium, więc pełne przeliczenie trwa kilka minut.

## Bibliografia


- C. E. Shannon, *A Mathematical Theory of Communication*, Bell System Technical Journal 27, 1948.
- D. A. Huffman, *A Method for the Construction of Minimum-Redundancy Codes*, Proceedings of the IRE 40(9), 1952.
- G. K. Zipf, *Human Behavior and the Principle of Least Effort*, Addison-Wesley, 1949.
- T. Kohonen, *Self-Organized Formation of Topologically Correct Feature Maps*, Biological Cybernetics 43, 1982.
- P. Qi, Y. Zhang, Y. Zhang, J. Bolton, C. D. Manning, *Stanza: A Python Natural Language Processing Toolkit for Many Human Languages*, ACL 2020 (System Demonstrations).
- Universal Dependencies – treebank UD_Serbian-SET, https://universaldependencies.org
- MediaWiki API (rozszerzenie TextExtracts), https://www.mediawiki.org/wiki/API:Main_page