Przetwarzanie języka naturalnego

Sprawozdanie z laboratoriów 1–4

Analiza korpusu języka serbskiego: entropia i kodowanie Huffmana, prawo Zipfa, graf sąsiedztwa wyrazów, sieć Kohonena

Autor	.....
Język korpusu	serbski (cyrylica, 30 liter)
Źródło danych	serbska Wikipedia (sr.wikipedia.org), API MediaWiki
Język programowania	Python 3 (numpy, scipy, matplotlib, networkx, stanza, reportlab)
Data	04.11.2026

1. Laboratorium 1 – wybór języka i pozyskanie korpusu

Cel: wybrać język, pobrać duży tekst w tym języku i zostawić z niego sam korpus wyrazów.

Wybrano **język serbski** zapisany cyrylicą. Tekst pobrano z serbskiej Wikipedii przez API MediaWiki (`action=query&prop=extracts&explaintext=1`). Skrypt `lab01.py` pobiera kolejne artykuły z listy, aż zbierze co najmniej 1 000 000 znaków. Pomija artykuły krótsze niż 5000 znaków (szablonowe zalążki) i duplikaty. Między zapytaniami robi 1,5-sekundową przerwę i przedstawia się nagłówkiem User-Agent, zgodnie z zasadami API Wikipedii.

Pobrano 20 artykułów: Србија, Историја Србије, Београд, Нови Сад, Ниш, Крагујевац, Војводина, Косово и Метохија, Црна Гора, Босна и Херцеговина, Хрватска, Југославија, Социјалистичка Федеративна Република Југославија, Краљевина Југославија, Краљевина Србија, Српско царство, Немањићи, Стефан Немања, Свети Сава, Стефан Душан.

Czyszczenie (`clean_text`): tekst zamieniany jest na małe litery, a każdy znak spoza 30-literowego alfabetu serbskiego (`абвгдђежзијклљмнњопрстћуфхцчџш`) zastępowany spacją. Usuwane są więc interpunkcja, cyfry, znaki specjalne, indeksy typu „²”, wyrazy w łacince i w alfabecie greckim. Na końcu wielokrotne białe znaki są zwijane do jednej spacji.

Przykład – fragment surowy i po oczyszczeniu:

```
Према истом извору, Вишеслав је потицао из лозе неименованог српског кнеза који је за време владавне
цара Ираклија (610–641) довео свој народ у Далмацију и околне области, зачетник је лозе Вишеславића.

према истом извору вишеслав је потицао из лозе неименованог српског кнеза који је за време владавне
цара ираклија довео свој народ у далмацију и околне области зачетник је лозе вишеславића
```

Wielkość	Wartość
Liczba znaków tekstu surowego	1 036 853
Liczba znaków po oczyszczeniu	967 373
Liczba wyrazów (tokenów)	149 373
Liczba różnych wyrazów	25 608
Liczba różnych znaków w korpusie	31 (30 liter + spacja)

Wynik zapisano w pliku `oczyszczony_serbski.txt`, a tekst surowy w `surowy_serbski.txt`. Tekstu surowego potrzebuje laboratorium 4, bo do analizy składniowej niezbędne są granice zdań.

2. Laboratorium 2 – statystyka liter, entropia i kodowanie Huffmana

Cel: upewnić się, że został sam korpus, policzyć udział procentowy (prawdopodobieństwo) każdej litery, entropię tekstu i kody Huffmana, a następnie porównać średnią długość kodu z entropią.

Skrypt `lab02_entropia_huffman.py` wczytuje korpus i jeszcze raz go czyści. Potem sprawdza, czy zostały w nim wyłącznie litery alfabetu serbskiego i spacje. Weryfikacja wypadła pomyślnie: korpus nie zawiera żadnych innych znaków, a występują w nim wszystkie 30 liter.

2.1. Prawdopodobieństwa liter i kody Huffmana

Tabela 1 pokazuje statystykę 30 liter w korpusie bez spacji (818 001 liter). Prawdopodobieństwo litery to p = n / N. Kody Huffmana zbudowano algorytmem zachłannym: dwa węzły o najmniejszych wagach są wielokrotnie łączone przy użyciu kolejki priorytetowej heapq.

Lp	Litera	Liczność	Udział [%]	p	$-\log_2 p$	Kod Huffmana	Dł.
1	а	98 931	12,094	0,12094	3,048	100	3
2	и	77 660	9,494	0,09494	3,397	001	3
3	о	75 716	9,256	0,09256	3,433	000	3
4	е	68 784	8,409	0,08409	3,572	1110	4
5	н	50 077	6,122	0,06122	4,030	0111	4
6	р	47 619	5,821	0,05821	4,102	0110	4
7	с	45 048	5,507	0,05507	4,183	0100	4
8	у	36 186	4,424	0,04424	4,499	11111	5
9	в	34 121	4,171	0,04171	4,583	11011	5
10	т	32 984	4,032	0,04032	4,632	11010	5
11	к	32 069	3,920	0,03920	4,673	11001	5
12	д	29 088	3,556	0,03556	4,814	11000	5
13	ј	28 824	3,524	0,03524	4,827	10110	5
14	п	23 457	2,868	0,02868	5,124	10100	5
15	м	23 324	2,851	0,02851	5,132	01011	5
16	л	23 043	2,817	0,02817	5,150	01010	5
17	г	15 722	1,922	0,01922	5,701	111100	6
18	б	13 411	1,639	0,01639	5,931	101011	6
19	з	13 235	1,618	0,01618	5,950	101010	6
20	ц	7 919	0,968	0,00968	6,691	1011111	7
21	ш	7 358	0,900	0,00900	6,797	1011110	7
22	ч	6 527	0,798	0,00798	6,970	1011100	7
23	х	5 682	0,695	0,00695	7,170	11110111	8
24	њ	5 273	0,645	0,00645	7,277	11110110	8
25	љ	4 104	0,502	0,00502	7,639	11110100	8
26	ћ	3 657	0,447	0,00447	7,805	10111011	8
27	ж	3 517	0,430	0,00430	7,862	10111010	8
28	ђ	2 367	0,289	0,00289	8,433	111101011	9
29	ф	2 155	0,263	0,00263	8,568	1111010101	10
30	џ	143	0,017	0,00017	12,482	1111010100	10
	Suma	818 001	100,000	1,00000			

Tabela 1. Udział liter w korpusie (bez spacji) i kody Huffmana.

2.2. Entropia i porównanie z kodem Huffmana

Entropia Shannona $H = -\Sigma\, p_i \log_2 p_i$ to dolna granica średniej liczby bitów na znak dla dowolnego kodu bezprefiksowego. Średnia długość kodu Huffmana to $L = \Sigma\, p_i \cdot l_i$. Policzono dwa warianty: same litery oraz litery ze spacją jako 31. symbolem.

Wariant	n	H [bit]	$H_{max} = \log_2 n$	Redund.	L Huffmana [bit]	L − H	H / L	Kod stały
same litery	30	4,3024	4,9069	12,32 %	4,3368	0,0344	99,21 %	5 bit
litery + spacja	31	4,2588	4,9542	14,04 %	4,2889	0,0301	99,30 %	5 bit

Tabela 2. Entropia a średnia długość kodu Huffmana.

Wnioski.

- Średnia długość kodu Huffmana (4,3368 bit) jest tylko o 0,0344 bitu większa od entropii (4,3024 bit). Spełniony jest warunek $H \leq L < H + 1$, a efektywność kodu wynosi 99,21%.
- Różnica L − H bierze się z tego, że długości słów kodowych muszą być liczbami całkowitymi, a prawdopodobieństwa liter nie są potęgami 1/2.
- W porównaniu z kodem o stałej długości (5 bitów na 30 liter) kod Huffmana skraca zapis tekstu o ok. 13,3%.
- Najczęstsze litery (а, и, о, е) dostają kody 3–4-bitowe, a najrzadsze (ђ, ф, џ) kody 8–9-bitowe.
- Kod sprawdzono, kodując i dekodując cały korpus: dekodowanie odtworzyło tekst bez zmian.

3. Laboratorium 3 – pokrycie tekstu, prawo Zipfa, graf sąsiedztwa

3.1. Wyrazy pokrywające 90% tekstu

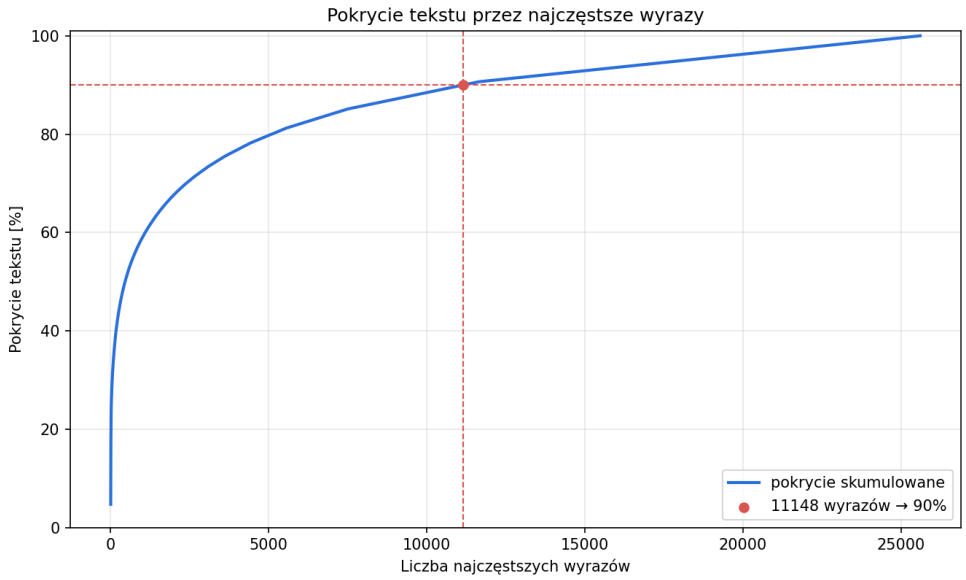
Korpus zawiera 149 373 wyrazów (tokenów) i 25 608 różnych wyrazów (typów). Wyrazy posortowano malejąco według liczności i sumowano ich udziały, aż łączny udział osiągnął 90%. **Do pokrycia 90% tekstu potrzeba 11 148 najczęstszych wyrazów**, czyli 43,53% słownika. Aż 13 984 wyrazów (54,6%) występuje tylko raz (tzw. hapax legomena).

Pokrycie tekstu	Liczba wyrazów	Udział w słowniku
25%	19	0,07%
50%	455	1,78%
75%	3 482	13,60%
80%	5 091	19,88%
90%	11 148	43,53%
95%	18 140	70,84%
99%	24 115	94,17%

Tabela 3. Liczba najczęstszych wyrazów potrzebna do pokrycia danej części tekstu.

Ranga	Wyraz	Liczność	Udział [%]	Pokrycie skum. [%]	Ranga	Wyraz	Liczność	Udział [%]	Pokrycie skum. [%]
1	и (i)	7099	4,7525	4,7525	11	а (a)	1110	0,7431	21,5621
2	је (jest)	6083	4,0724	8,8249	12	за (za / dla)	1059	0,7090	22,2711
3	у (w)	5270	3,5281	12,3530	13	који (który)	748	0,5008	22,7719
4	на (na)	2440	1,6335	13,9865	14	као (jako)	726	0,4860	23,2579
5	су (są)	2273	1,5217	15,5082	15	из (z)	715	0,4787	23,7366
6	се (się)	2214	1,4822	16,9904	16	до (do)	652	0,4365	24,1730
7	да (że / żeby)	1537	1,0290	18,0193	17	србије (Serbii)	586	0,3923	24,5653
8	године (roku)	1473	0,9861	19,0054	18	био (był)	427	0,2859	24,8512
9	од (od)	1438	0,9627	19,9681	19	по (po)	343	0,2296	25,0808
10	са (z)	1271	0,8509	20,8190	20	о (o)	342	0,2290	25,3098

Tabela 4. 20 najczęstszych wyrazów korpusu. Pełna lista 11 148 wyrazów jest w pliku wyniki/lab03/wyrazy_pokrycie_90.csv.



Rys. 1. Pokrycie tekstu przez najczęstsze wyrazy.

3.2. Prawo Zipfa

Prawo Zipfa mówi, że częstość wyrazu jest odwrotnie proporcjonalna do jego rangi: $f(r) \approx C / r^s$, gdzie $s \approx 1$. Wtedy iloczyn $r \cdot f(r)$ jest w przybliżeniu stały. Parametry wyznaczono regresją liniową

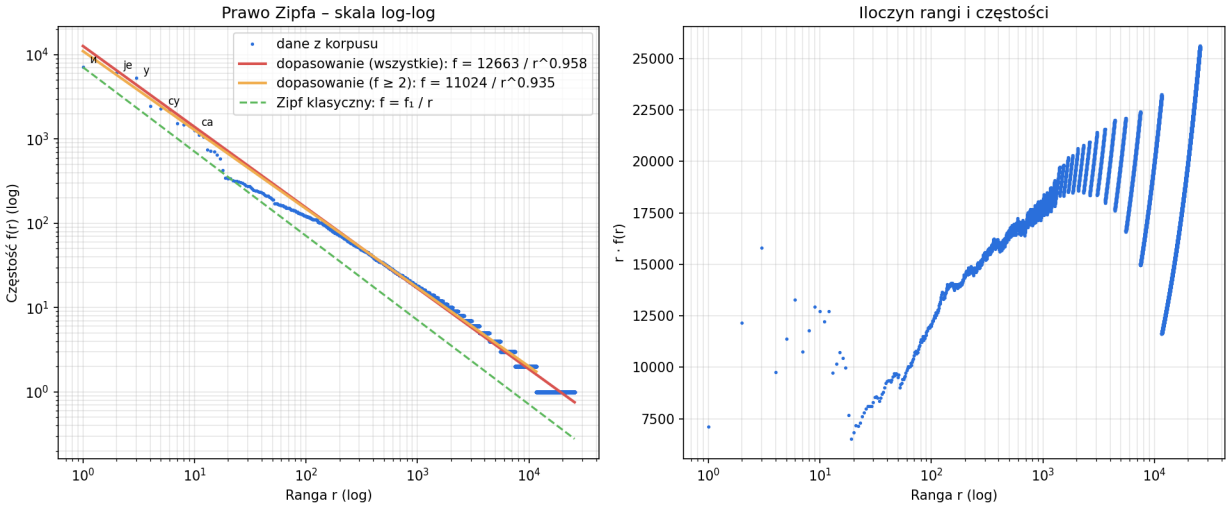
w skali log-log: log f = log C − s · log r.

Dopasowanie	Wykładnik s	C	R²
wszystkie wyrazy (25 608)	0,9584	12 663,4	0,9652
bez hapaksów, f ≥ 2 (11 624)	0,9351		

Tabela 5. Parametry prawa Zipfa dla korpusu.

Ranga r	Wyraz	f(r)	r · f(r)
1	и (i)	7099	7 099
2	је (jest)	6083	12 166
3	у (w)	5270	15 810
5	су (są)	2273	11 365
10	са (z)	1271	12 710
20	о (o)	342	6 840
50	државе (państwa)	190	9 500
100	један (jeden)	120	12 000
200	друге (drugie / inne)	72	14 400
500	освојио (zdobył)	33	16 500
1000	војно (wojskowo)	18	18 000
2000	повратка (powrotu)	10	20 000
5000	стручне (fachowej)	4	20 000

Tabela 6. Iloczyn rangi i częstości dla wybranych rang.



Rys. 2. Prawo Zipfa: częstość w funkcji rangi (log-log) oraz iloczyn r · f(r).

Wniosek. W skali log-log punkty układają się niemal na prostej (R² = 0,965), a wykładnik s = 0,96 jest bliski klasycznej wartości 1, więc korpus spełnia prawo Zipfa. Odchylenia widać dla kilku pierwszych rang (słowa funkcyjne и, у, је) oraz w ogonie, gdzie wiele wyrazów ma tę samą małą częstość (schodki na wykresie). Lekkie spłaszczenie rozkładu (s < 1) wynika z odmiany wyrazów w serbskim: formy србија, србије, србији, србију liczone są osobno. Przy dziesięciokrotnie mniejszym korpusie (100 tys. znaków) wykładnik wynosił tylko 0,68, co pokazuje, że prawo Zipfa ujawnia się wyraźnie dopiero na dużych tekstach.

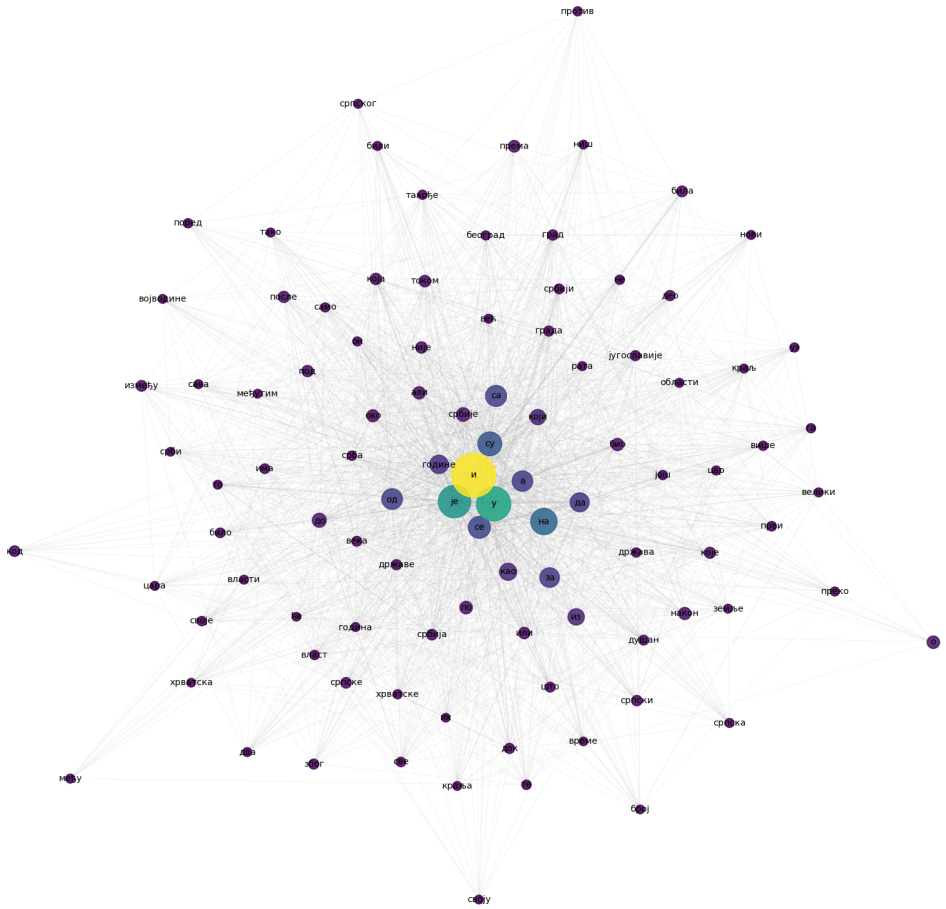
3.3. Graf wyrazów sąsiadujących i jego rdzeń

Graf zbudowano tak: węzłem jest wyraz, a krawędź łączy dwa wyrazy, które choć raz stoją w tekście bezpośrednio obok siebie. Dla każdego węzła zliczono krawędzie wychodzące (różne wyrazy występujące bezpośrednio po nim), wchodzące (różne wyrazy występujące bezpośrednio przed nim) oraz liczbę wszystkich różnych sąsiadów. **Rdzeń** grafu to 100 wyrazów o największej liczbie sąsiadów.

Wielkość	Wartość
Liczba węzłów (różnych wyrazów)	25 608
Liczba krawędzi skierowanych (a → b)	99 265
Liczba krawędzi nieskierowanych (a — b)	95 855
Średnia / mediana liczby sąsiadów	7,49 / 2
Maksymalna liczba sąsiadów	6 800 (и)

Lp	Wyraz	Sąs.	Wych.	Wch.	Częst.	Lp	Wyraz	Sąs.	Wych.	Wch.	Częst.
1	и (i)	6800	3986	3773	7099	51	први (pierwszy)	191	91	106	173
2	у (w)	4059	1695	2617	5270	52	све (wszystko)	188	82	114	152
3	је (jest)	3602	2435	1835	6083	53	те (te / oraz)	188	82	113	131
4	на (na)	2328	1029	1401	2440	54	срба (Serbów)	178	79	106	204
5	су (są)	1878	1183	938	2273	55	своје (swoje)	178	94	88	119
6	се (się)	1572	1080	681	2214	56	власт (władza)	177	110	78	173
7	са (z)	1433	703	765	1271	57	не (nie)	176	85	93	140
8	од (od)	1382	714	749	1438	58	више (więcej)	172	94	85	159
9	а (a)	1351	587	830	1110	59	држава (państwo)	171	86	97	153
10	за (za / dla)	1228	607	663	1059	60	поред (obok / oprócz)	170	78	94	114
11	да (że / żeby)	1149	487	704	1537	61	још (jeszcze)	169	79	98	151
12	године (roku)	1064	719	441	1473	62	га (go)	168	95	80	150
13	као (jako)	904	389	535	726	63	против (przeciw)	168	77	97	146
14	из (z)	814	346	484	715	64	такође (także)	166	94	77	141
15	који (który)	691	131	567	748	65	хрватске (Chorwacji)	165	84	87	123
16	до (do)	562	334	271	652	66	уз (przy / wraz z)	163	75	89	116
17	србије (Serbii)	521	279	260	586	67	београд (Belgrad)	161	70	104	157
18	по (po)	423	207	225	343	68	само (tylko)	159	86	80	110
19	о (o)	417	233	188	342	69	међу (pośród)	156	63	93	118
20	али (ale)	402	104	305	341	70	он (on)	154	61	98	165
21	био (był)	397	221	189	427	71	били (byli)	154	81	78	145
22	након (po)	390	163	234	317	72	српска (serbska)	154	69	93	127
23	око (około)	379	202	197	317	73	преко (przez)	154	83	79	101
24	према (według / ku)	347	164	187	238	74	рата (wojny)	153	112	45	171
25	током (podczas)	336	139	207	268	75	цар (car)	153	79	83	167
26	или (lub)	328	169	186	211	76	велики (wielki)	153	51	104	151
27	није (nie jest)	326	156	172	276	77	области (obwodu / dziedziny)	152	86	74	114
28	која (która)	324	66	259	325	78	два (dwa)	151	87	69	128
29	под (pod)	318	128	193	280	79	тако (tak)	149	34	119	142
30	после (po)	314	152	165	243	80	српског (serbskiego)	149	50	103	137
31	које (które)	305	67	240	307	81	већ (już)	149	68	88	133
32	била (była)	277	173	114	290	82	нови (nowy)	148	41	110	171
33	између (między)	276	119	160	213	83	то (to)	146	91	70	216
34	код (u / przy)	266	135	138	197	84	сава (Sawa)	146	73	80	164
35	српске (serbskiej)	262	100	172	242	85	цара (cara)	145	77	71	163
36	србија (Serbia)	260	113	164	277	86	земље (kraju / ziemi)	145	79	75	107
37	српски (serbski)	252	118	142	237	87	власти (władzy)	144	87	59	128
38	град (miasto)	245	126	139	237	88	војводине (Wojwodiny)	144	82	65	126
39	део (część)	237	142	102	223	89	краљ (król)	143	63	89	168
40	док (podczas gdy)	233	40	197	228	90	година (rok / lat)	143	91	63	137
41	града (miasta)	230	116	123	233	91	краља (króla)	142	65	80	143
42	државе (państwa)	228	126	108	190	92	ниш (Nisz)	139	75	71	130
43	због (z powodu)	221	97	126	151	93	своју (swoją)	137	66	73	104
44	југославије (Jugosławii)	219	128	99	212	94	међутим (jednak)	137	64	76	81
45	што (co)	212	49	168	312	95	број (liczba)	135	82	56	122
46	века (wieku)	212	163	58	246	96	срби (Serbowie)	131	65	75	130
47	душан (Duszan)	208	81	136	258	97	ће (będzie)	131	83	51	129
48	србији (w Serbii)	206	159	50	300	98	их (ich)	131	66	70	120
49	има (ma)	198	106	97	162	99	хрватска (Chorwacja)	130	57	82	112
50	било (było)	197	122	84	202	100	време (czas)	129	112	20	157

Tabela 7. Rdzeń grafu – 100 wyrazów o największej liczbie sąsiadów (Sąs. – różni sąsiedzi, Wych./Wch. – krawędzie wychodzące/wchodzące, Częst. – liczność).


Rdzeń grafu: 100 wyrazów o największej liczbie sąsiadów
(wielkość węzła = liczba sąsiadów w całym grafie, grubość krawędzi = liczba wystąpień pary)
и
је
у
се
на
да
не
са
су
од
за
као
али
или
што
који
када
после
године
србије
србија
србије
србије
србије

- Rdzeń tworzą głównie słowa funkcyjne: spójniki (и, а, али), przyimki (у, на, од, са, за) i formy czasownika бити (је, су). Łączą się one z bardzo wieloma różnymi wyrazami.
- Rozkład liczby sąsiadów jest silnie skośny i w skali log-log zbliżony do potęgowego. Mediana to tylko 2 sąsiadów, a maksimum przekracza 6000. Graf ma więc strukturę „bezskalową” z kilkoma silnie połączonymi hubami.
- Ranking według samych krawędzi wychodzących daje rdzeń pokrywający się z powyższym w ok. 83%. Obie miary są podane w tabeli.

4. Laboratorium 4 – sieć Kohonena dla rzeczowników i czasowników przechodnich

Cel: wybrać 50 rzeczowników i 100 czasowników przechodnich. Każdy rzeczownik opisać wektorem o 100 składowych, w którym składowa i to liczba kolokacji rzeczownika z i-tym czasownikiem. Te 50 wektorów tworzy zbiór treningowy dla sieci Kohonena. Mapa sieci pokazuje, jak rzeczowniki układają się w 100-wymiarowej przestrzeni czasowników. Na koniec sprawdzono, jak wynik zależy od wyboru czasowników.

4.1. Analiza składniowa korpusu

Żeby wiedzieć, który rzeczownik jest dopełnieniem którego czasownika i które czasowniki są przechodnie, potrzebna jest analiza morfologiczna i składniowa. Użyto biblioteki **stanza** (Stanford NLP) z modelem dla języka serbskiego (treebank SETimes.SR, standard Universal Dependencies). Skrypt `lab04_parsowanie.py`:

- wczytuje tekst surowy z lab 1 (z interpunkcją, bo potrzebne są granice zdań) i usuwa z niego nagłówki sekcji Wikipedii,
- transliteruje cyrylicę na łacinkę, bo model był trenowany na serbskiej łacince. Alfabety serbskie odpowiadają sobie 1:1, np. љ → lj, њ → nj, џ → dž, ћ → ć,
- wykonuje tokenizację, znakowanie częściami mowy (UPOS), lematyzację i parsowanie zależnościowe,
- przepisuje lematy z powrotem na cyrylicę i zapisuje wynik do `dane/korpus_sparsowany.tsv.gz`.

Wynik: 7 949 zdań, 178 663 tokenów (razem ze znakami interpunkcji), 1 679 różnych lematów czasowników, 5 203 różnych lematów rzeczowników oraz **3 890 relacji czasownik → dopełnienie rzeczownikowe** (relacja `obj`). Przykład analizy zdania „Кнез Лазар је подигао цркву и водио војску”: obj(подићи, црква), obj(водити, војска).

4.2. Wybór czasowników przechodnich i rzeczowników

Czasownik przechodni to taki, który łączy się z dopełnieniem bliższym w bierniku (relacja `obj`). Wybrano **100 czasowników, które najczęściej występują w korpusie z dopełnieniem rzeczownikowym**. Pominięto czasowniki posiłkowe i modalne (бити, хтети, моћи). Dopełnienia współrzędne też są liczone: w zdaniu „подигао цркву и кућу” oba rzeczowniki są dopełnieniami czasownika. Następnie wybrano **50 rzeczowników, które najczęściej są dopełnieniem tych czasowników**. Dzięki temu każdy rzeczownik ma niezerowy wektor cech.

Lp	Czasownik	Dop.	Wyst.	Lp	Czasownik	Dop.	Wyst.
1	имати (mieć)	364	393	51	напустити (opuścić)	14	23
2	чинити (stanowić / czynić)	100	142	52	примити (przyjąć / otrzymać)	13	21
3	представљати (przedstawiać / stanowić)	99	99	53	променити (zmienić)	13	11
4	добити (otrzymać)	79	98	54	обновити (odnowić)	13	21
5	освојити (zdobyć)	58	95	55	потписати (podpisać)	13	19
6	обухватати (obejmować)	52	46	56	осетити (odczuć)	13	11
7	донети (przynieść / uchwalić)	47	51	57	пружати (stawiać / udzielać)	12	15
8	послати (wysłać)	41	57	58	признавати (uznawać)	12	15
9	дати (dać)	37	51	59	предати (przekazać / poddać)	12	28
10	прихватити (przyjąć)	31	41	60	штитити (chronić)	12	9
11	заузимати (zajmować)	30	43	61	издати (wydać)	12	16
12	признати (uznać)	28	42	62	називати (nazywać)	11	33
13	водити (prowadzić)	27	49	63	сачињавати (tworzyć / stanowić)	11	12
14	преузети (przejąć)	27	30	64	пружити (stawić / udzielić)	11	13
15	прогласити (ogłosić / proklamować)	27	44	65	уживати (cieszyć się (czymś))	11	10
16	наставити (kontynuować)	26	47	66	мењати (zmieniać)	11	14
17	оставити (zostawić)	26	42	67	усвојити (przyjąć / uchwalić)	11	12
18	повратити (odzyskać)	24	23	68	поставити (postawić / ustanowić)	10	17
19	заузети (zająć)	24	57	69	наћи (znaleźć)	10	44

Lp	Czasownik	Dop.	Wyst.	Lp	Czasownik	Dop.	Wyst.
20	стећи (zdobyć / nabyć)	23	27	70	настављати (kontynuować)	10	19
21	формирати (utworzyć)	23	38	71	постићи (osiągnąć)	10	18
22	извршити (wykonać / dokonać)	23	25	72	узети (wziąć)	10	15
23	носити (nosić)	22	25	73	одржавати (utrzymywać)	10	38
24	користити (używać)	22	43	74	изазивати (wywoływać)	10	11
25	доносити (przynosić / uchwalać)	22	17	75	преузимати (przejmować)	10	13
26	основати (założyć)	21	34	76	бирати (wybierać)	10	26
27	изгубити (stracić)	21	25	77	потврдити (potwierdzić)	10	9
28	подићи (wznieść / podnieść)	21	28	78	склопити (zawrzeć)	10	12
29	вршити (pełnić / sprawować)	21	24	79	покривати (pokrywać)	9	9
30	давати (dawać)	20	21	80	насељавати (zamieszkiwać)	9	18
31	организовати (organizować)	19	30	81	износити (wynosić)	9	47
32	добијати (otrzymywać)	19	27	82	карактерисати (charakteryzować)	9	9
33	покретати (wszczynać / uruchamiać)	18	19	83	увести (wprowadzić)	9	15
34	однети (odnieść)	17	19	84	освајати (zdobywać)	9	27
35	укључивати (obejmować / włączać)	17	20	85	започети (rozpocząć)	9	16
36	нудити (oferować)	17	10	86	ојачати (wzmocnić)	9	15
37	доживети (przeżyć / doznać)	16	19	87	чувати (strzec / przechowywać)	9	13
38	обављати (wykonywać)	16	23	88	поседовати (posiadać)	9	12
39	повезивати (łączyć)	16	33	89	означити (oznaczyć)	9	10
40	задржати (zachować)	16	29	90	држати (trzymać)	9	21
41	изазвати (wywołać)	16	16	91	подразумевати (oznaczać / zakładać)	9	10
42	створити (stworzyć)	15	20	92	пратити (śledzić / towarzyszyć)	9	10
43	тражити (szukać / żądać)	15	31	93	убити (zabić)	9	17
44	покренути (wszcząć / uruchomić)	15	19	94	завршити (zakończyć)	9	18
45	напасти (zaatakować)	15	40	95	именовати (mianować)	9	11
46	успоставити (ustanowić)	14	16	96	одржати (utrzymać / przeprowadzić)	9	23
47	садржати (zawierać)	14	12	97	испунити (spełnić)	9	8
48	остварити (osiągnąć)	14	24	98	проглашавати (ogłaszać)	8	13
49	искористити (wykorzystać)	14	21	99	проширити (rozszerzyć)	8	25
50	немати (nie mieć)	14	26	100	претрпети (ponieść / doznać)	8	9

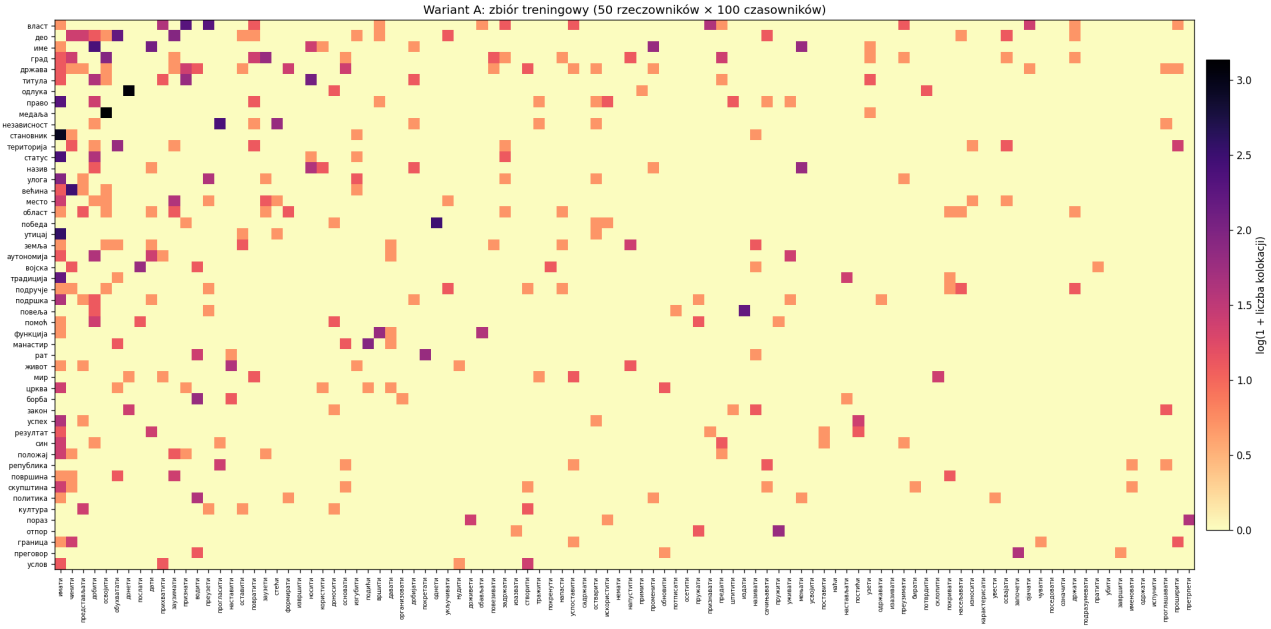
Tabela 8. 100 wybranych czasowników przechodnich (Dop. – liczba dopełnień rzeczownikowych, Wyst. – liczba wystąpień czasownika w korpusie).

Lp	Rzeczownik	Jako dop.	Wyst.	Lp	Rzeczownik	Jako dop.	Wyst.
1	власт (władza)	43	340	26	подршка (poparcie)	12	34
2	део (część)	35	453	27	повеља (przywilej / karta)	12	54
3	име (imię / nazwa)	34	172	28	помоћ (pomoc)	11	76
4	град (miasto)	34	686	29	функција (funkcja)	11	22
5	држава (państwo)	27	459	30	манастир (monaster)	11	78
6	титула (tytuł)	26	84	31	рат (wojna)	10	385
7	одлука (decyzja)	26	111	32	живот (życie)	10	105
8	право (prawo)	23	96	33	мир (pokój)	10	60
9	медаља (medal)	23	36	34	црква (cerkiew)	10	190
10	независност (niepodległość)	21	84	35	борба (walka)	9	101
11	становник (mieszkaniec)	21	136	36	закон (ustawa / prawo)	9	89
12	територија (terytorium)	18	236	37	успех (sukces)	9	22
13	статус (status)	18	44	38	резултат (wynik)	9	45
14	назив (nazwa)	17	98	39	син (syn)	9	150
15	улога (rola)	17	31	40	положај (położenie / pozycja)	9	63
16	већина (większość)	16	78	41	република (republika)	9	310
17	место (miejsce)	16	126	42	површина (powierzchnia)	9	57
18	област (obwód / dziedzina)	15	206	43	скупштина (zgromadzenie / parlament)	9	137
19	победа (zwycięstwo)	15	52	44	политика (polityka)	9	62
20	утицај (wpływ)	15	68	45	култура (kultura)	8	117
21	земља (kraj / ziemia)	14	286	46	пораз (porażka)	8	38
22	аутономија (autonomia)	14	36	47	отпор (opór)	8	43
23	војска (wojsko)	13	240	48	граница (granica)	8	120
24	традиција (tradycja)	13	42	49	преговор (negocjacje)	8	49
25	подручје (obszar)	13	196	50	услов (warunek)	8	31

Tabela 9. 50 wybranych rzeczowników (Jako dop. – ile razy były dopełnieniem wybranych czasowników).

4.3. Zbiór treningowy – wektory 100-wymiarowe

Dla każdego z 50 rzeczowników zbudowano wektor $x \in R^{100}$, w którym x_j to liczba wystąpień rzeczownika jako dopełnienia j-tego czasownika. Macierz 50 × 100 zawiera łącznie 762 kolokacji; niezerowych jest 338 składowych (6,8%). Przed uczeniem liczności przekształcono funkcją log(1 + x), żeby kilka bardzo częstych par nie zdominowało wektora, a następnie każdy wektor znormalizowano do długości 1. Odległość euklidesowa między wektorami odpowiada wtedy podobieństwu kosinusowemu, a porównywane są proporcje czasowników, a nie częstość rzeczownika.

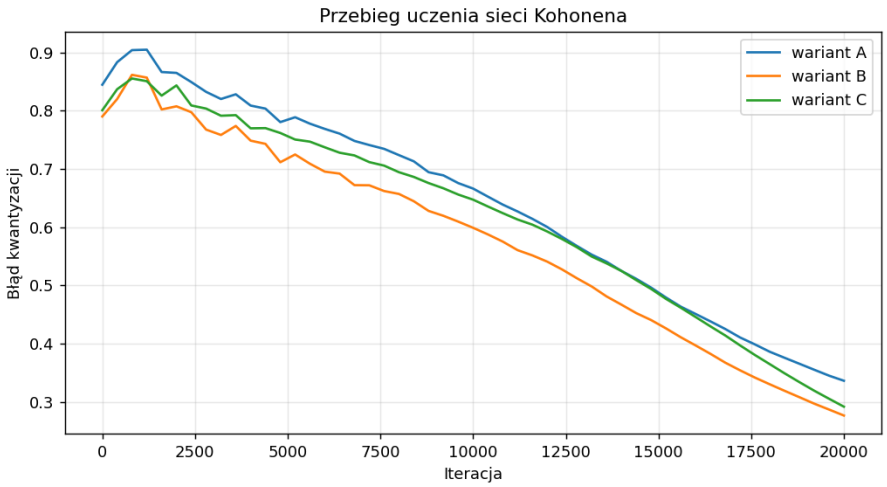


Rys. 5. Zbiór treningowy (wariant A): 50 rzeczowników × 100 czasowników, skala log(1 + n).

4.4. Sieć Kohonena

Sieć Kohonena (samoorganizująca się mapa, SOM) zaimplementowano samodzielnie w numpy (klasa `KohonenSOM`). Ma 10 × 10 = 100 neuronów ułożonych w prostokątną siatkę. Każdy neuron ma wektor wag w tej samej 100-wymiarowej przestrzeni co dane. Algorytm uczenia:

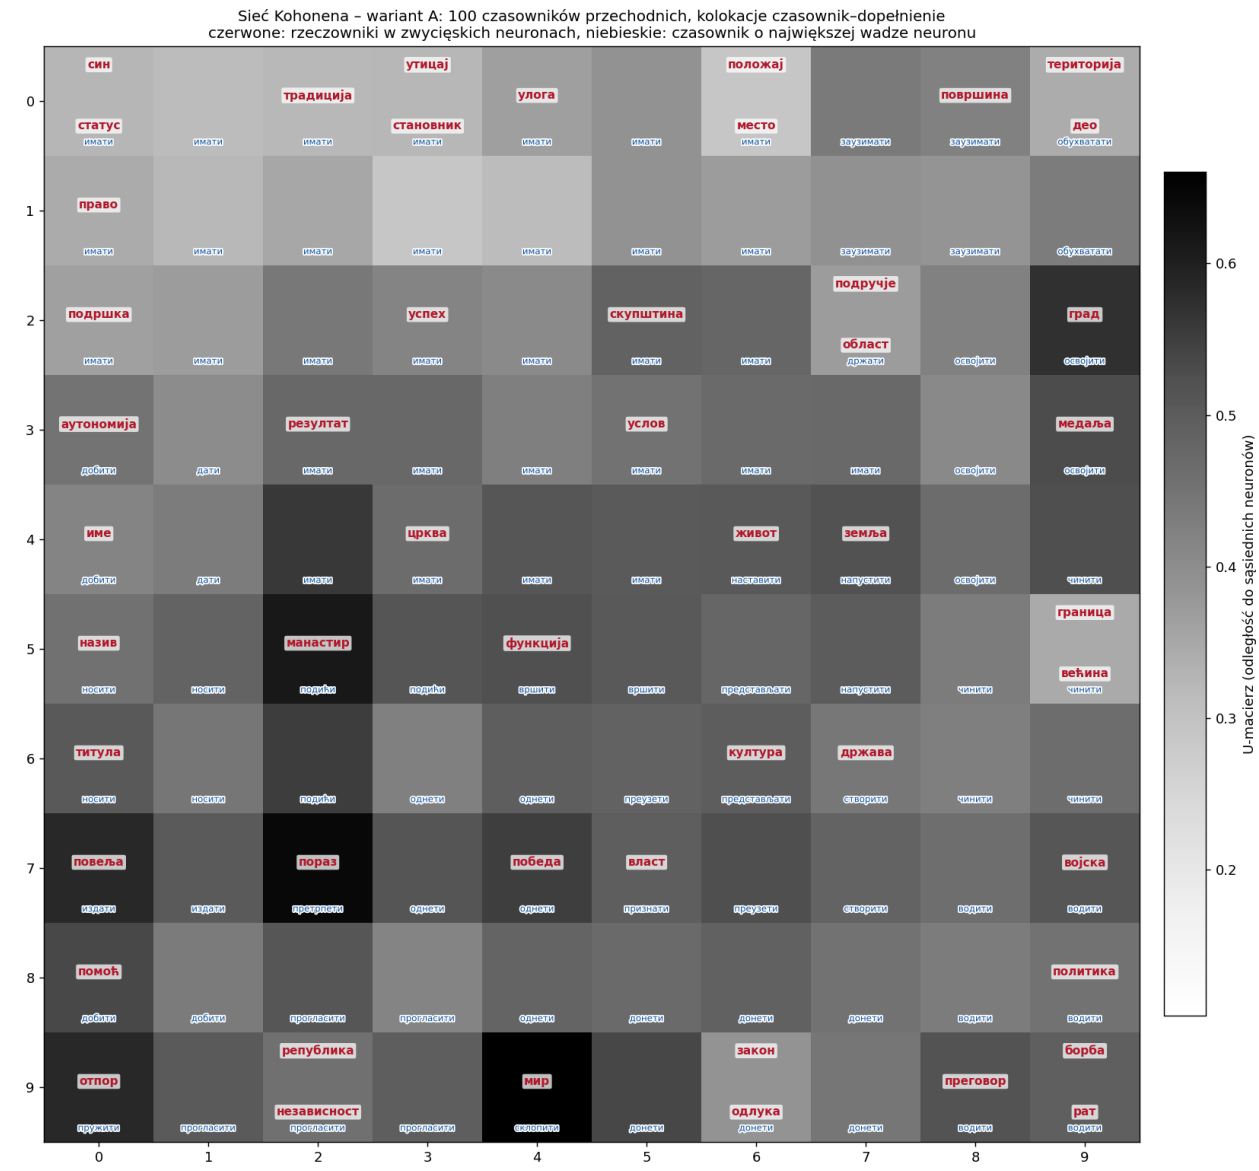
- inicjalizacja wag na płaszczyźnie dwóch pierwszych składowych głównych (PCA) danych,
- 20 000 iteracji: losujemy wektor x i znajdujemy neuron zwycięski (BMU), czyli najbliższy w sensie odległości euklidesowej,
- aktualizacja wag: $w \leftarrow w + \eta(t) \cdot h(t) \cdot (x - w)$, gdzie $h = \exp(-d^2 / 2\sigma(t)^2)$ jest gaussowską funkcją sąsiedztwa na siatce,
- współczynnik uczenia η maleje wykładniczo z 0,5 do 0,01, a promień sąsiedztwa σ z 5 do 0,5,
- jakość mapy: błąd kwantyzacji (średnia odległość wektora od wag jego BMU) i błąd topograficzny (odsetek wektorów, których dwa najlepsze neurony nie sąsiadują ze sobą).



Rys. 6. Spadek błędu kwantyzacji w trakcie uczenia.

4.5. Wynik – mapa rzeczowników w przestrzeni czasowników przechodnich

Na mapie (Rys. 7) każdy rzeczownik umieszczono w jego neuronie zwycięskim. Tło to U-macierz: ciemne pola oznaczają duże odległości między sąsiednimi neuronami, czyli granice skupień. W każdym neuronie podpisano też czasownik, którego składowa ma w nim największą wagę. W ten sposób widać, które wymiary 100-wymiarowej przestrzeni dominują w danym rejonie mapy.



Rys. 7. Mapa Kohonena – wariant A (błąd kwantyzacji 0,336, błąd topograficzny 0,0%).

Rzeczowniki, które trafiły do tego samego neuronu, mają najbardziej podobne wektory kolokacji: део (część), територија (terytorium); одлука (decyzja), закон (ustawa / prawo); независност (niepodległość), република (republika); становник (mieszkaniec), утицај (wpływ); статус (status), син (syn); већина (większość), граница (granica); место (miejsce), положај (położenie / pozycja); област (obwód / dziedzina), подручје (obszar); рат (wojna), борба (walka).

Interpretacja mapy. Sieć bez nadzoru podzieliła rzeczowniki na obszary wyznaczone przez czasowniki, z którymi się łączą:

• **górne wiersze** – rejon czasownika *имати* (mieć): статус, традиција, становник, утицај, улога, право, подршка, успех („mieć status, tradycję, mieszkańców, wpływ, rolę, prawo, poparcie, sukces”);

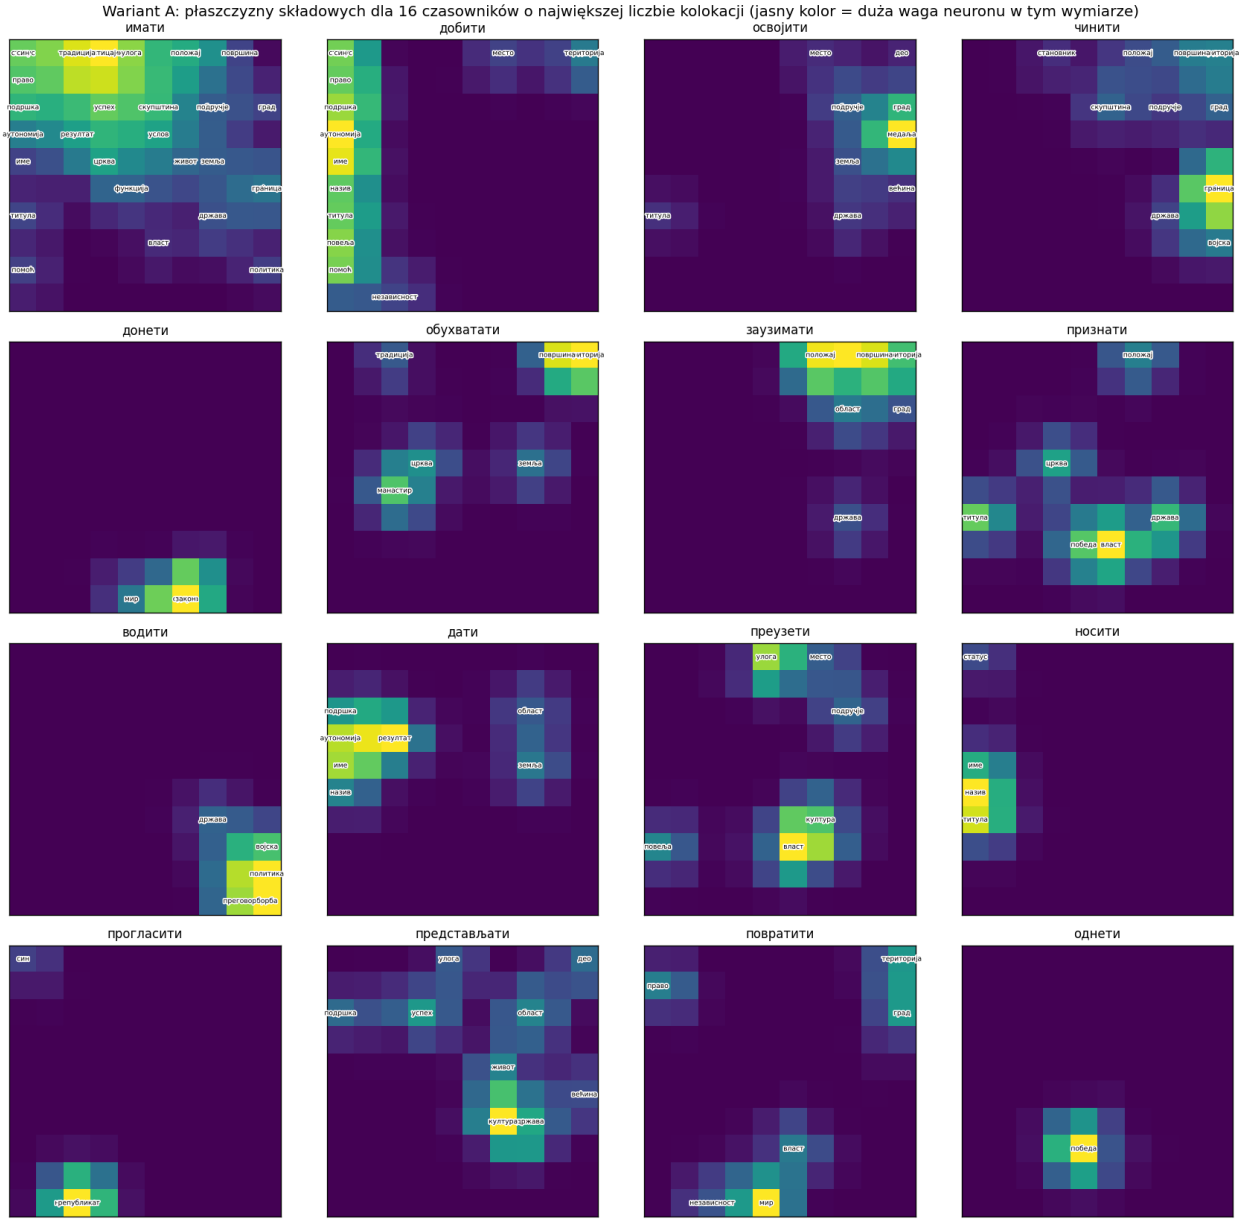
• **prawy górny róg** – rzeczowniki przestrzenne z czasownikami *заузимати* (zajmować) i *обухватати* (obejmować): место, положај, површина, део, територија, подручје, област;

• **lewa kolumna** – rzeczy, które się otrzymuje, nadaje lub nosi (*добити, дати, носити, издати, пружити*): аутономија, име, назив, титула, повеља, помоћ, отпор;

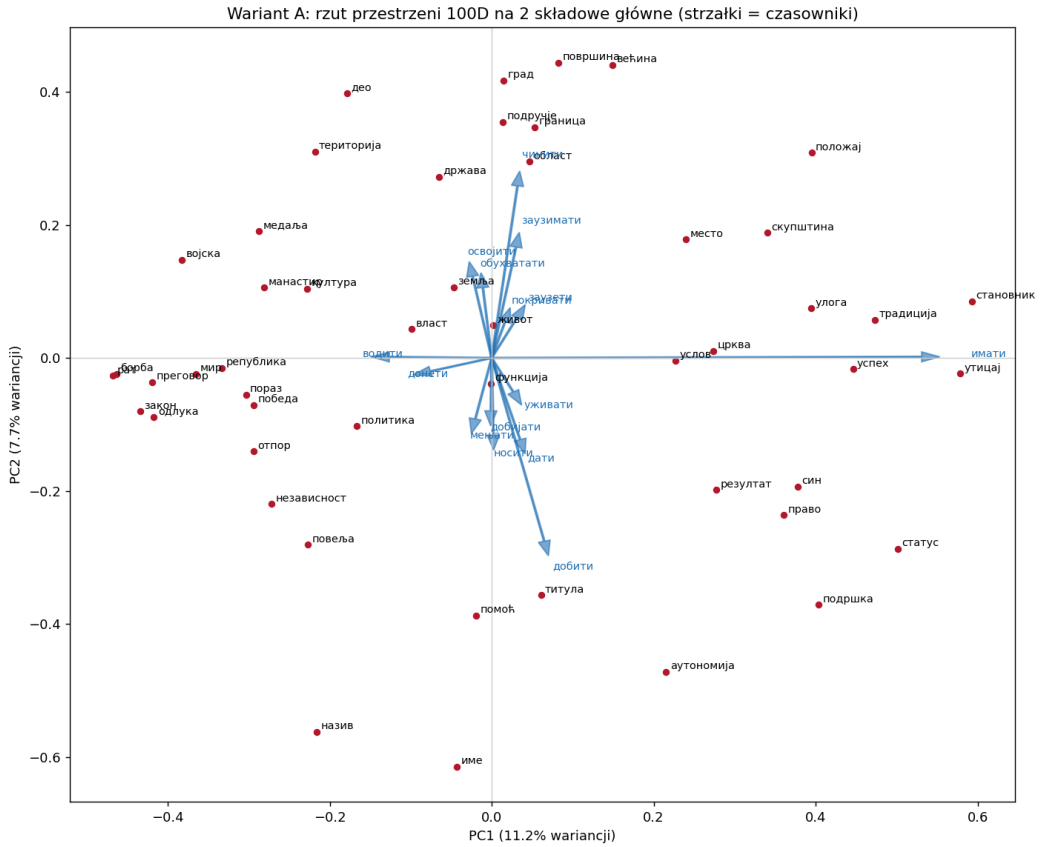
• **dolny wiersz** – działania polityczne i wojskowe: независност и република (*прогласити* – ogłosić), одлука и закон (*донети* – podjąć, uchwalić), мир (*склопити* – zawrzeć), преговор, борба, рат, политика, војска (*водити* – prowadzić);

• **środek dołu mapy** – пораз (*претрпети* – ponieść), победа (*однети* – odnieść), власт (*преузети* – przejąć).

Ciekawym przypadkiem są град (miasto) і медаља (medal) leżące obok siebie. Łączy je czasownik *освојити*, który znaczy zarówno „zdobyć miasto”, jak і „zdobyć medal”. Mapa grupuje więc rzeczowniki według zachowania składniowego (wspólnych czasowników), a nie według samego znaczenia. Błąd topograficzny wynosi 0%: rzeczowniki podobne w przestrzeni 100D leżą na mapie obok siebie.



Rys. 8. Płaszczyzny składowych: rozkład wag neuronów dla 16 czasowników o największej liczbie kolokacji. Jasny obszar to rejon mapy, w którym leżą rzeczowniki łączące się z danym czasownikiem.



Rys. 9. Dla porównania: rzut liniowy PCA tych samych wektorów 100D na płaszczyznę. Strzałki pokazują kierunki osi najważniejszych czasowników.

Porównanie z PCA (Rys. 9) pokazuje przewagę sieci Kohonena. Dwie pierwsze składowe główne wyjaśniają łącznie tylko 18,8% wariancji, a PC1 to w praktyce oś czasownika *имати*. Rzut liniowy gubi więc większość informacji ze 100 wymiarów i część punktów nakłada się na siebie. Sieć Kohonena jest nieliniowa: korzysta z całej przestrzeni 100D, rozkłada rzeczowniki po siatce i zachowuje ich sąsiedztwo.

4.6. Wpływ wyboru czasowników na wynik

Wynik zależy od tego, które czasowniki są wymiarami przestrzeni. Ten sam zbiór 50 rzeczowników nauczono więc w trzech wariantach, przy identycznych parametrach sieci:

- **Wariant A** – 100 czasowników przechodnich, kolokacje czasownik–dopełnienie.
- **Wariant B** – 100 najczęstszych czasowników, kolokacje czasownik–dopełnienie.
- **Wariant C** – 100 czasowników przechodnich, kolokacje w oknie ±5 wyrazów.

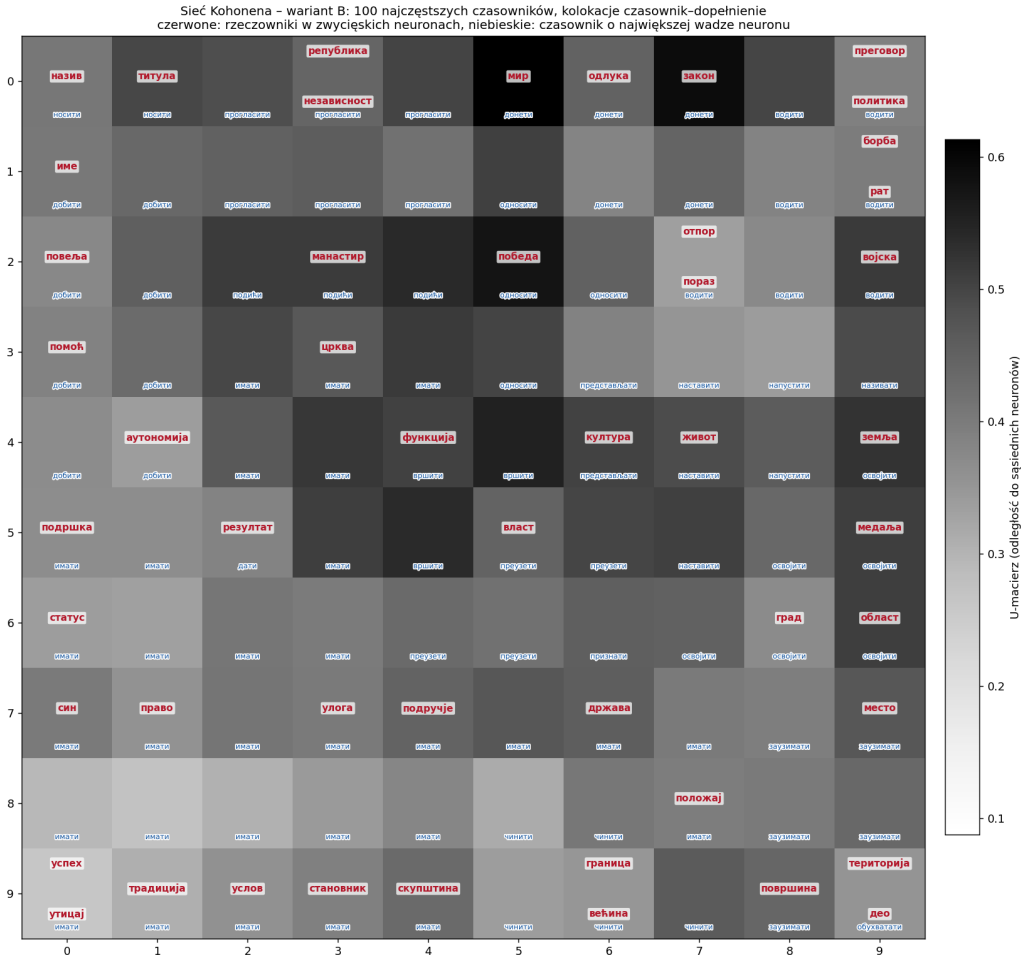
Warianty A i B mają 49 wspólnych czasowników na 100. W wariancie B są też częste czasowniki nieprzechodnie lub zwrotne (np. налазити се, постати), które prawie nie mają dopełnień rzeczownikowych.

Wariant	Suma kolokacji	Gęstość macierzy	Rzeczowniki z zerowym wektorem	Błąd kwantyzacji	Błąd topograficzny	Zajęte neurony
A	762	6,8%	0	0,336	0,0%	41
B	617	5,3%	2	0,276	0,0%	43
C	1 784	16,5%	0	0,292	0,0%	49

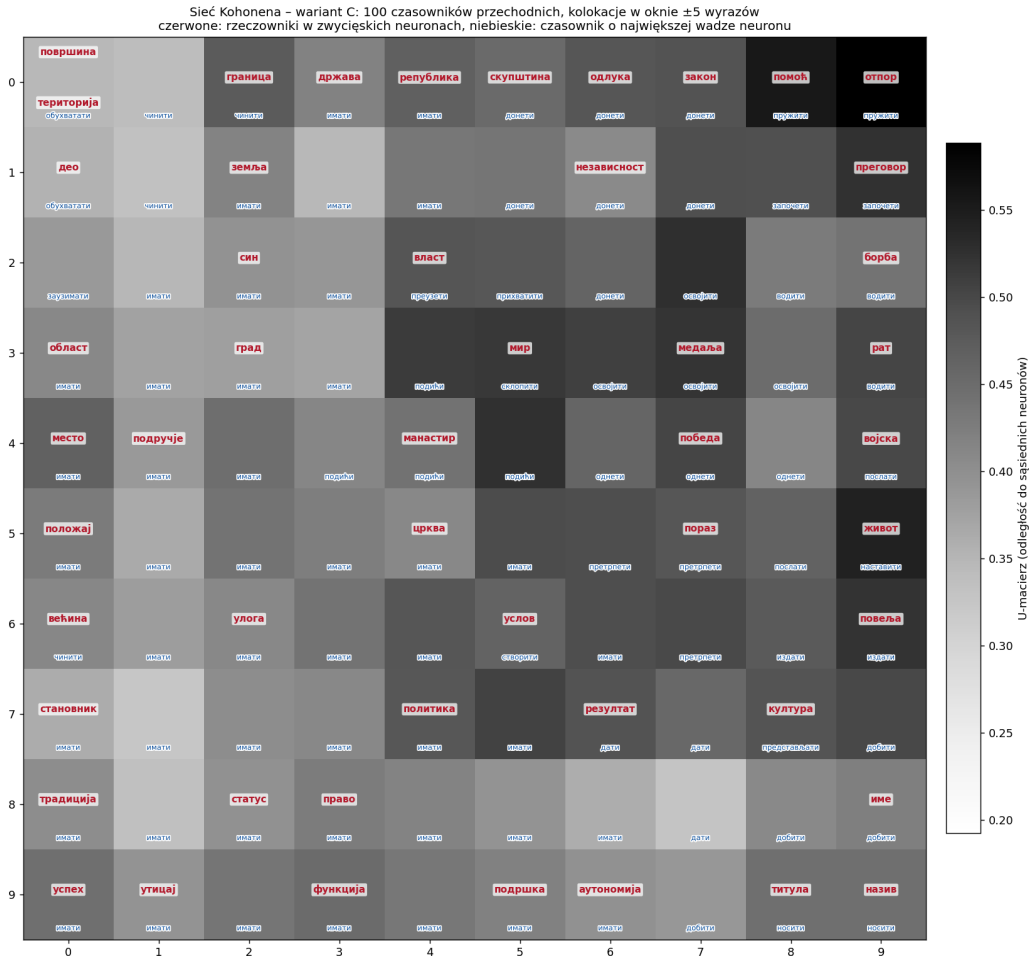
Tabela 10. Porównanie wariantów.

Porównanie	Korelacja Spearmana odległości na mapie	Wspólni sąsiedzi (5 najbliższych)
A – B	0,701	48,0%
A – C	0,405	30,0%
B – C	0,429	30,0%

Tabela 11. Podobieństwo map uzyskanych w różnych wariantach. Korelacja 1 oznacza identyczny układ wzajemnych odległości rzeczowników.



Rys. 10. Mapa Kohonena – wariant B.



Rys. 11. Mapa Kohonena – wariant C.

Wnioski z porównania. Wynik wyraźnie zależy od wyboru czasowników:

• **A i B** mają wspólną połowę czasowników, w tym te o największej liczbie kolokacji (имати, донети, водити, прогласити, освојити). Dlatego ogólny układ mapy jest podobny (korelacja odległości ok. 0,7), ale tylko około połowy najbliższych sąsiadów się pokrywa. W wariancie B znalazło się wiele czasowników nieprzechodnich (дођи, живети, ићи, умрети...), które nie wnoszą informacji o dopełnieniu. Rzeczowniki пораз i отпор mają w B zerowe wektory, bo ich jedyne czasowniki (претрпети, пружити) nie należą do 100 najczęstszych. Trafiają więc do jednego neuronu nie z podobieństwa, lecz z braku danych.

• **C** (okno ±5 wyrazów zamiast relacji składniowej) daje gęstszą macierz, ale bardziej zaszumioną. W oknie łapane są też podmioty i wyrazy niezwiązane z czasownikiem: np. град dostaje 22 kolokacje z *имати* ze zdań typu „град има … становника” (miasto ma … mieszkańców), w których jest podmiotem, a nie dopełnieniem. Mapa C najmniej przypomina pozostałe, choć najsilniejsze pary (одлука–закон, рат–борба, територија–површина) nadal leżą obok siebie.

Najbardziej wiarygodna jest więc mapa A, w której wymiarami są czasowniki faktycznie przechodnie, a kolokacje pochodzą z relacji czasownik–dopełnienie.

5. Podsumowanie

W ramach czterech laboratoriów zbudowano i przeanalizowano korpus języka serbskiego (ok. 1 mln znaków z 20 artykułów Wikipedii). Najważniejsze wyniki:

• **Lab 1:** po oczyszczeniu w korpusie zostały wyłącznie wyrazy z 30 liter serbskiej cyrylicy (149 tys. wyrazów, 25,6 tys. różnych).

• **Lab 2:** entropia liter wynosi ok. 4,30 bit/znak, a kod Huffmana osiąga średnio 4,34 bit/znak (efektywność 99,2%, $H \le L < H + 1$). Względem kodu 5-bitowego to oszczędność ok. 13%.

• **Lab 3:** 90% tekstu pokrywa ok. 11 tys. najczęstszych wyrazów (43,5% słownika). Korpus spełnia prawo Zipfa z wykładnikiem $s \approx 0{,}96$. Rdzeń grafu sąsiedztwa tworzą słowa funkcyjne (и, у, је, на, су…).

• **Lab 4:** analiza składniowa pozwoliła wybrać 100 czasowników przechodnich i 50 rzeczowników będących ich dopełnieniami. Sieć Kohonena nauczona na 100-wymiarowych wektorach kolokacji pogrupowała rzeczowniki w czytelne obszary semantyczno-składniowe, np. posiadanie, przestrzeń, nadawanie nazw i tytułów, działania polityczne i wojskowe. Porównanie trzech wariantów pokazało, że mapa w dużym stopniu zależy od tego, jakie czasowniki są wymiarami przestrzeni i jak definiujemy kolokację.

Struktura programu (repozytorium)

Plik	Zawartość
lab01.py	pobranie artykułów z serbskiej Wikipedii i oczyszczenie korpusu
lab02_entropia_huffman.py	statystyka liter, entropia, kodowanie Huffmana
lab03_wyrazy_zipf_graf.py	pokrycie 90% tekstu, prawo Zipfa, graf sąsiedztwa i rdzeń
lab04_parsowanie.py	analiza składniowa korpusu (stanza, transliteracja cyrylica ↔ łacinka)
lab04_kohonen.py	wybór czasowników i rzeczowników, zbiór treningowy, sieć Kohonena
generuj_sprawozdanie.py, slownik.py	generowanie tego sprawozdania
dane/, wyniki/	korpus sparsowany oraz wszystkie tabele CSV, raporty i wykresy

Kolejność uruchamiania: `pip install -r requirements.txt`, a potem lab01.py → lab02_entropia_huffman.py → lab03_wyrazy_zipf_graf.py → lab04_parsowanie.py → lab04_kohonen.py → generuj_sprawozdanie.py.